

数据与预处理

Data, EDA & preprocessing

先理解数据的语义，再选择表示与算法。/ Meaning before modeling.

01 学习任务 / Learning tasks

Task 任务	Input → output 输入与输出
Clustering 聚类	Unlabeled data → groups 无标签数据 → 相似对象的分组
Classification 分类	Features + labels → category 特征与标签 → 类别
Regression 回归	Features + targets → value 特征与目标值 → 连续数值
Association rules 关联规则	Transactions → co-occurrence 交易集合 → 共现规则 $X \rightarrow Y$

Generalization 泛化：规律应能用于未见数据。
A useful pattern should hold on unseen data.

辨析 / Distinguish

Correlation $\neq$ causation 相关不等于因果。
Good training fit $\neq$ good generalization.
训练表现好，不代表新数据上也好。

02 属性类型 / Attribute types

Type 类型	Meaning & example 含义与例子
Nominal 名义	Only identity 类别标签，无大小意义 ID、邮编、颜色
Ordinal 有序	Order, not equal gaps 有顺序但不等距 学历、满意度等级
Interval 区间	Meaningful differences, no true zero 差值有意义，无绝对零点：摄氏温度
Ratio 比率	Meaningful ratios 有真实零点、可比倍数 重量、长度、年龄

Type follows semantics, not storage.

数值存储不等于数值属性；整数 ID 仍是 nominal。20°C 不是 10°C 的“两倍热”。

03 数据形态 / Data representations

Record 记录：一行对象、多列属性。

Graph 图：节点及关系； $G=(V,E)$ 。

Ordered 有序：时间序列、空间或顺序数据。

Structured / semi-structured / unstructured：结构化 / 半结构化 / 非结构化。

04 数据质量 / Data quality & EDA

Noise 噪声：测量或记录的扰动。

Outlier 离群点：与其他点显著不同，可能是错误，也可能是异常检测的目标。

Missing 缺失：未知或未采集，不能自动当作 0。

Duplicate 重复：多个记录对应同一实体。

Histogram 直方图 → 分布 distribution。

Boxplot 箱线图 → 单变量异常 univariate outliers。

Scatter plot 散点图 → 变量关系 relationships。

Check class balance 检查各类样本比例。

易错 / Pitfall

A suspicious distribution is a clue, not proof.

分布异常只是调查线索。单变量正常，不代表多变量组合正常；箱线图不能找出所有离群点。

05 预处理 / Preprocessing

Cleaning 清洗：补缺失、去重、修正单位。

Reduction 约简：抽样、特征选择、降维。

Aggregation 聚合：日期 → 年份。

Binning + smoothing 分箱平滑：用箱内均值等替换原值，降低细节与部分噪声。

Discretization 离散化：连续值 → 有序类别。

One-hot 独热编码：名义类别 → 多个 0/1 特征，避免强加顺序，通常增加维度。

06 缩放 / Feature scaling

$$\text{Min-max: } x' = (x - \min) / (\max - \min)$$

$$\text{Z-score: } x' = (x - \mu) / \sigma$$

μ = mean 均值； σ = standard deviation 标准差。常数特征的分母为 0，需单独处理。

Scaling matters for distance-based methods.

KNN / K-Means 的距离会受到量纲影响。

手算 / Quick calculation

训练 min=10, max=50； $x=30 \rightarrow 0.5$ 。

若 $\mu=25, \sigma=5$ ； $x=30 \rightarrow z=1$ 。

测试 $x=60 \rightarrow \text{min-max}=1.25$ ，可超出 [0,1]。

Fit preprocessing on training data only.

先切分，再只用训练集拟合 μ 、 σ 、min、max；验证/测试沿用同一变换。标准化不会自动把数据变成正态分布。

聚类分析

Clustering: centers, density & hierarchy

聚类没有唯一标准；距离与簇的定义决定结果。/ Similarity defines the grouping.

01 K-Means / 均值聚类

$$SSE = \sum_k \sum_{x \in C_k} \|x - \mu_k\|^2$$

$$\mu_k = (1/|C_k|) \sum_{x \in C_k} x$$

Initialize → assign → update → repeat.

初始化 K 个中心 → 点分给最近中心 → 中心取簇内均值 → 分组不变时停止。

Fixed assignments: the mean minimizes SSE.

固定簇时，均值最小化平方误差。每步 SSE 不增加；收敛不保证全局最优。

手算 / One iteration

数据 {1,2,3,8,9,10}，初始中心 1、3。
等距归第 1 簇 → {1,2} 和 {3,8,9,10}。
更新为 1.5、7.5；再次分配再更新 → 2、9。
最终 SSE=1+0+1+1+0+1=4。

Limits 局限：初始化、尺度、离群点敏感；偏好紧凑近球状簇，不擅长不同大小/密度或非球状簇。K 增大时最优 SSE 不升，不能只靠最小 SSE 选 K。

02 变体 / Variants

K-Means++：只改初始化；下一中心按到最近已有中心的距离平方 $D(x)^2$ 加权抽样。

Probability $\propto D(x)^2$; not always the farthest.

K-Medoids：中心选实际样本；只需距离，不要求均值；通常更抗离群点，更新更贵。

X-Means：尝试拆分子簇，用 BIC/AIC 等准则判断是否保留拆分，从而探索 K。

03 DBSCAN / 密度聚类

ϵ = radius 半径；MinPts = density threshold 最低邻域点数。

本课邻域包含自身 / Count the point itself.

Point 点	Condition 条件
Core 核心	$ N_\epsilon(x) \geq \text{MinPts}$
Border 边界	非核心点，但邻接某核心点
Noise 噪声	既非核心，也非边界

Expand only from core points.

由核心点递归扩展；边界点不能继续“搭桥”。暂标 noise 的点后来可能成为 border。

04 DBSCAN 判断要点 / Caveats

No preset K; noise may be excluded.

不用指定簇数；允许不属于任何簇的噪声。

Non-globular shapes 非球状簇可处理。

Varying densities 不同密度通常难兼顾。

k-distance elbow 可用于初选 ϵ 。

常考判断 / Checks

MinPts=4，周围有 3 个其他点 → core。

最少簇数可以为 0：全部都是 noise。

同参数下核心点结构固定，但邻接两簇的边界点归属可能依赖访问顺序。

05 AGNES / 凝聚层次聚类

Start with N singleton clusters; merge the nearest pair until one cluster remains.

一点一簇，反复合并最近两簇。Dendrogram 树状图可在不同高度切开得到不同分组。

Linkage 连接	Distance between A, B 簇间距离
Single 单链	$\min_{a \in A, b \in B} d(a, b)$ 易出现 chaining 链式连接
Complete 全链	$\max_{a \in A, b \in B} d(a, b)$ 偏好紧凑簇
Average 平均	$\sum_{a, b} d(a, b) / (A B)$ 所有跨簇点对，不是中心距离
Centroid 质心	$d(\mu_A, \mu_B)$
Ward	合并导致的 SSE 增量 ΔSSE

$$\Delta SSE = [n_A n_B / (n_A + n_B)] \times \|\mu_A - \mu_B\|^2$$

A={1,2}, B={6,8}：single=4；complete=7；average=5.5；Ward=30.25。

Distance matrix 距离矩阵：空间 $O(N^2)$ 。

Naive AGNES 朴素算法：时间 $O(N^3)$ 。

06 评价 / Evaluation

External 外部：purity、Rand index (需真实标签)。

Internal 内部：SSE elbow、silhouette。指标有形状偏好，没有万能标准。

$$\text{Silhouette: } s(i) = [b(i) - a(i)] / \max(a(i), b(i))$$

a：到同簇其他点的平均距离。b：到其他各簇的平均距离之最小值。接近 1 好；接近 0 近边界；负值提示可能错分。单点簇通常记 0。

关联规则挖掘

Association rules & Apriori

先判断共现强度，再利用包含关系减少搜索。 / Measure association, then prune.

01 定义 / Definitions

Transaction 交易：物品集合。Itemset 项集：物品子集。

k-itemset：含 k 个物品。

Rule 规则 $X \rightarrow Y$ ：X, Y 非空且 $X \cap Y = \emptyset$ 。

Antecedent 前件 X；consequent 后件 Y。

$SC(X) = \# \text{ transactions containing } X$

$S(X) = SC(X)/N$

Frequent 频繁 $\Leftrightarrow S(X) \geq \text{minsup}$

S 用比例，SC 用次数。门槛 minsup 对应最低计数 $\text{ceil}(N \times \text{minsup})$ 。

Rules describe co-occurrence, not causality.

规则描述共现，不表示因果。

02 三指标 / Three measures

$\text{Support}(X \rightarrow Y) = S(X \cup Y)$

$\text{Confidence}(X \rightarrow Y) = S(X \cup Y)/S(X)$

$= P(Y|X)$

$\text{Lift}(X \rightarrow Y) = S(X \cup Y)/[S(X)S(Y)]$

$= \text{Confidence}/S(Y)$

Support 支持度：有多少交易同时含全部物品？

Confidence 置信度：有 X 时，Y 多常见？

Lift 提升度：比 Y 自身的出现率高多少倍？

Lift	Interpretation 含义
> 1	Positive association 正关联
$= 1$	该 X、Y 事件满足独立关系
< 1	Negative association 负关联

手算 / Counts $\rightarrow$ measures

$N=100$, $SC(X)=40$, $SC(Y)=80$, $SC(XY)=30$ 。

Support=0.30；Confidence=0.75；

Lift=0.75/0.80=0.9375。

置信度 75% 看似高，仍低于 Y 的总体概率。

Symmetry 对称性：support、lift 对换 X/Y 不变；

confidence 通常有方向。

若 $S(X)>0$ ，则 $\text{support} \leq \text{confidence} \leq 1$ 。

$S(X)=0$ 时 confidence 未定义。

03 搜索规模 / Search space

d items $\rightarrow 2^d - 1$ nonempty itemsets

Possible rules: $3^d - 2^{d+1} + 1$

k-itemset $\rightarrow 2^k - 2$ rules

04 Apriori principle / 反单调性

$A \subseteq B \Rightarrow S(A) \geq S(B)$

Frequent set $\Rightarrow$ all subsets frequent.

频繁项集的所有子集都频繁。

Infrequent set $\Rightarrow$ all supersets infrequent.

不频繁项集的所有超集都不频繁。

不能反推 / Converse is false

子集都频繁，不保证整个项集频繁。

Support anti-monotonicity does not apply to lift.

Lift 不能直接套用支持度的剪枝规则。

05 Apriori algorithm / 算法流程

本课记号： L_k = candidates 候选项集；

F_k = frequent sets 频繁项集。

1. Generate 生成：从 F_{k-1} 扩展/连接出 L_k ，并去重。

2. Prune 剪枝：若任一 $(k-1)$ 子集不在 F_{k-1} ，删除该候选。

3. Count 计数：扫描数据库求剩余候选的 SC。

4. Filter 过滤：只保留达到 minsup 的候选。

Stop if F_k is empty. F_k 为空则停止。

手算 / Candidate pruning

交易：ABC, AB, AC, ABC, B；minsup=0.6。

F_1 ：A(4), B(4), C(3)。

F_2 ：AB(3), AC(3)；BC(2) 被淘汰。

ABC 含不频繁的 BC $\rightarrow$ 不必计数，直接剪掉。

06 生成规则 / Rule generation

For each frequent itemset S, split it into $X \rightarrow (S - X)$; keep confidence $\geq \text{minconf}$.

对频繁项集作非空二分，再检查置信度；复用已有支持计数，不必重扫数据库。

Fix $S = X \cup Y$ 固定整个项集：

larger consequent $Y \rightarrow$ smaller antecedent X

$\rightarrow$ confidence cannot increase

固定 S 时，扩大后件会缩小前件；分子 $S(S)$ 不变，分母 $S(X)$ 不减，故 confidence 不增。

规则剪枝 / Confidence pruning

固定 $S=ABCD$ 。若 $ABC \rightarrow D$ 置信度不足，则 $AB \rightarrow CD$ 、

$A \rightarrow BCD$ 等后件包含 D 的规则也不足。

Do not compare arbitrary rules this way.

不能把这个结论用于并集不同的任意两条规则。

Pass BOTH thresholds 同时满足两阈值；任一不足即淘汰。
保留单项计数，以计算 confidence / lift。

分类、KNN 与决策树

Evaluation, nearest neighbors & decision trees

先选对评价指标，再比较模型与分裂。 / Choose the metric before judging the model.

01 混淆矩阵 / Confusion matrix

预测 ↓ / 真实 →	Positive 正	Negative 负
Positive 正	TP 真正例	FP 误报
Negative 负	FN 漏报	TN 真负例

Read axis labels first. 先看坐标轴；其他资料可能把行列反过来。本表与讲义：行是预测、列是真实。

Accuracy = (TP+TN)/N
 Precision = TP/(TP+FP)
 Recall = Sensitivity = TP/(TP+FN)
 Specificity = TN/(TN+FP)
 F1 = 2PR/(P+R)
 = 2TP/(2TP+FP+FN)

Precision：“判正的有多少是真的？”

Recall：“真正为正的找出多少？”

F1 uses harmonic mean 调和平均，惩罚一高一低。分母为 0 时指标需按约定处理。

手算 / Example

TP=40, FP=10, FN=20, TN=130 :
 Accuracy=.85 ; Precision=.80 ; Recall=.6667 ; F1=.7273。
 类别不平衡时只看 accuracy 可能误导；99% 负类时，全猜负也有 99% accuracy。

02 多分类 / Multiclass averaging

One-vs-Rest：每类轮流作为正类。

Micro：先汇总 TP/FP/FN，再计算指标；大类影响较大。

Pool counts, then compute.

Macro：先分别计算每类指标，再等权平均。Compute per class, then average.

Single-label, all classes included：

micro-P = micro-R = micro-F1 = accuracy.

Macro-F1 = average of per-class F1.

不是将 macro-P/R 代入 F1 公式。

03 KNN / 最近邻预测

Classification → majority vote 多数投票。

Regression → mean of targets 目标均值。

Small k：高方差，易拟合噪声。

Large k：更平滑，可能欠拟合。

距离依赖缩放与表示；高维中距离可能趋同 (curse of dimensionality 维度灾难)。

Odd k only helps binary ties.

奇数 k 不能保证多分类无平票。KNN 的 k 是邻居数；

K-Means 的 K 是簇数。

04 CART / 贪心树分裂

Greedy local split, not globally optimal.

每次选当前最优分裂，不保证整棵树全局最优。分类叶子预测多数类；回归叶子预测均值。

$$\text{Gini}(t) = 1 - \sum_c p(c|t)^2$$

$$\text{Entropy}(t) = -\sum_c p(c|t) \log_2 p(c|t)$$

$$I_{\text{split}} = \sum_j (N_j/N) I(\text{child}_j)$$

$$\text{Gain} = I(\text{parent}) - I_{\text{split}}$$

Pure node → impurity 0. 纯节点不纯度为 0；约定 $0 \log 0 = 0$ 。

Weight children by sample counts.

子节点必须按样本数加权，不能直接平均。

讲义手算 / Split example, p.78

父节点 5 Yes/4 No : Gini=40/81≈.49383。

分成 (0 Yes, 3 No) 与 (5 Yes, 1 No)：

$$I_{\text{split}} = (3/9) \times 0 + (6/9) \times (5/18) = 5/27。$$

$$\text{Gain} = 25/81 \approx .30864。$$

另一分裂 (3,2) 与 (2,2) 的 Gain≈.00494。

Do not round early. 中间过程不要过早舍入。

05 候选与回归 / Splits & regression

Numerical 数值：不同值排序后，在相邻值间试阈值。

Nominal 名义：d 个类别，非空无序二分数量为 $2^{d-1}-1$ 。

Ordinal 有序：保持自然顺序时有 d-1 个切点。

$$\text{RSS}_{\text{split}} = \sum_j \sum_{i \in \text{child } j} (y_i - \text{mean}(y)_j)^2$$

Choose minimum total RSS.

回归分裂最小化子节点 RSS 总和，不直接相加各节点方差；方差除以了节点样本数。

06 过拟合与剪枝 / Pruning

Deep trees can memorize training data.

深树易记住训练数据、具有高方差。

Pre-pruning 预剪枝：限制深度、最小分裂样本数、最小叶样本数等。

Post-pruning 后剪枝：先建树，再依据验证表现等准则删分裂。

边界条件 / Boundary cases

N 个可区分样本，根深度为 0，树最大深度可达 N-1（每次只分出一个点）。

若特征完全相同但目标冲突，则不能靠继续分裂实现完美训练拟合。

线性模型与验证

Linear / logistic regression & validation

模型决定表达能力；损失定义错误；优化学习参数。 / Model → loss → optimization.

01 线性回归 / Linear regression

$$\hat{y} = \theta_0 + \sum_{j=1}^d \theta_j x_j = \mathbf{x}^T \boldsymbol{\theta}$$

$$L = (1/n) \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|^2 = \text{MSE}$$

$$\nabla L = (2/n) \mathbf{X}^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$$

含截距： $x_0=1$ ， $\mathbf{X}$ 尺寸为 $n \times (d+1)$ 。

θ_j ：其他特征固定时， x_j 增加 1 单位的预测变化量。不是因果效应。

Normal equation 正规方程：

$$\boldsymbol{\theta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

General solution via pseudoinverse: $\boldsymbol{\theta} = \mathbf{X}^+ \mathbf{y}$

Inverse formula needs full column rank.

直接求逆要求满列秩；共线性或参数多于样本可导致奇异。求逆约 $O(d^3)$ ，还需构造 $\mathbf{X}^T \mathbf{X}$ 。秩不足时可用伪逆求最小范数最小二乘解。

02 梯度下降 / Gradient descent

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla L(\boldsymbol{\theta})$$

η = learning rate 学习率。梯度指向上升方向，因此减梯度。过大可能发散/振荡，过小收敛慢；同时用旧参数算所有分量再更新。

Batch：全数据；SGD：单样本；mini-batch：一小批。

手算 / One GD step

数据 (1,2),(2,3)， $\boldsymbol{\theta}=(0,0)$ ， $\eta=.1$ 。

MSE 使用 $1/n$ ：梯度= $(-5,-8)$ 。

新 $\boldsymbol{\theta}=(.5,.8)$ 。若损失用 $1/(2n)$ ，梯度减半。

03 多项式与正则 / Polynomial & L2

$\hat{y}=\theta_0+\theta_1x+\theta_2x^2$ ：仍对 $\boldsymbol{\theta}$ 线性。

Linear in parameters, not necessarily inputs.

二元二次项： $1, x_1, x_2, x_1^2, x_1x_2, x_2^2$ 。

d 个原始特征、最高 p 次，含常数项共 $C(d+p,p)$ 项。

$$L_{\text{reg}} = \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|^2/n + (\lambda/n) \sum_{j \geq 1} \theta_j^2$$

$$\mathbf{D} = \text{diag}(0, 1, \dots, 1)$$

$$\boldsymbol{\theta} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{D})^{-1} \mathbf{X}^T \mathbf{y}$$

$$\nabla L_{\text{reg}} = 2\mathbf{X}^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})/n + 2\lambda \mathbf{D} \boldsymbol{\theta}/n$$

No penalty on intercept θ_0 . 通常不罚截距。

λ 越大约束越强，可能欠拟合。正则化关注泛化，不保证降低训练 MSE。缩放会改变系数和相对惩罚。

04 逻辑回归 / Logistic regression

$$\mathbf{z} = \mathbf{x}^T \boldsymbol{\theta}, \quad p = \sigma(\mathbf{z}) = 1/(1+e^{-\mathbf{z}})$$

$$P(\mathbf{y}|\mathbf{x}) = p^{\mathbf{y}}(1-p)^{1-\mathbf{y}}$$

$$L = -(1/n) \sum_i [y_i \ln p_i + (1-y_i) \ln (1-p_i)]$$

$$\nabla L = (1/n) \mathbf{X}^T (\mathbf{p} - \mathbf{y})$$

$p = P(\mathbf{y}=1|\mathbf{x})$ ，真实标签 $y \in \{0,1\}$ 。

Binary cross-entropy = negative log-likelihood.

二元交叉熵来自最大似然。无普通正规方程闭式解，通常迭代优化。

Predict 1 if $p \geq \tau$. 阈值 $\tau=.5$ 时边界为 $\mathbf{x}^T \boldsymbol{\theta}=0$ ；加多项式特征后，原空间边界可非线性。提高阈值会减少预测正例（同一批固定概率）。

手算 / Probability vs decision

$y=1, p=.8$ ：分对，但 $\text{loss} = -\ln(.8) \approx .2231$ 。

$y=1, p=.01$ ： $\text{loss} \approx 4.605$ ，自信分错惩罚大。

改阈值只改分类决定，不改 p 或当前交叉熵。

05 凸性与缩放 / Convexity & scaling

OLS 与标准 logistic loss 对参数均为凸。

Convex does not imply a unique finite optimum.

凸不等于必有唯一有限最小值：无正则逻辑回归遇完全线性可分数据，参数可能不断增大。

无正则线性回归：可逆仿射特征缩放在精确优化等通常条件下保留预测表达能力；系数会变。Scaling may improve GD conditioning.

缩放可改善梯度下降数值条件，但不是产生更强模型。

06 验证与泄漏 / Validation & leakage

Split 数据集	Purpose 用途
Training 训练	Fit parameters 拟合参数 $\boldsymbol{\theta}$
Validation 验证	Select model/hyperparameters 选择模型与 k 、深度、 λ 等
Test 测试	Final evaluation 最终评价 不能反复依其表现调参

K-fold CV：将开发数据分 K 折，轮流 1 折验证、 $K-1$ 折训练，汇总分数。最终测试集保持隔离。

必须记住 / Leakage checklist

Split → fit preprocessing on train → transform all.

先切分；只用训练集拟合缩放、填补等参数。

Each CV fold needs its own fitted pipeline.

交叉验证每一折也只用本折训练部分拟合预处理。

集成学习

Bagging, random forests & boosting

互补的错误，才让模型组合更有效。 / Diversity makes aggregation useful.

01 组合方式 / Ensemble patterns

Voting 投票：独立模型投票/平均。

Stacking 堆叠：用元模型学习如何组合基模型预测；元模型训练也要避免泄漏。

Bagging：不同 bootstrap 数据上独立训练。

Boosting：后续模型依赖已有模型，逐轮纠错。

02 Bagging & Random Forest

Bootstrap：从 N 条记录有放回抽样 N 次。

Sample with replacement; repeats allowed.

每个抽样集可有重复、遗漏的记录。各树独立，可并行；分类投票，回归平均。

Random Forest = bootstrap sampling
+ random feature subset at EACH split

每个分裂处只考虑随机特征子集，减少强特征造成的树间相关性，从而增强方差降低效果。

Lower correlation → more useful averaging.

标准 RF 不是每棵树固定一套特征。更多树通常不单独导致更严重过拟合，但增加计算成本。

03 AdaBoost / 调整样本权重

Initialize $w_i=1/N$ ；每轮训练弱分类器 h_m ，在原训练集上按当前权重计算错误率。

Weighted error, not raw error count.

$\epsilon_m = \sum_i w_i I[h_m(x_i) \neq y_i]$
 $\alpha_m = \frac{1}{2} \ln[(1-\epsilon_m)/\epsilon_m]$
 Wrong 错分： $w_i \leftarrow w_i e^{\alpha_m}$
 Correct 正确： $w_i \leftarrow w_i e^{-\alpha_m}$
 Normalize 归一化： $w_i \leftarrow w_i / \sum_j w_j$

下一轮更关注错分点。可加权训练或按权重重新采样。预测时按 α 加权投票；若标签为 ± 1 ： $\text{sign}(\sum_m \alpha_m h_m(x))$ 。

手算与边界 / Example & limits

$\epsilon=.2 \rightarrow \alpha=\frac{1}{2}\ln 4 \approx .693$ 。
 错分权重 $\times 2$ ，正确权重 $\times .5$ ，再归一化；相对权重比扩大 4 倍。

$\epsilon=.5 \rightarrow \alpha=0$ ； $\epsilon>.5 \rightarrow \alpha<0$ ，需处理。
 $\epsilon=0$ 时需停止或进行数值保护。

Weak learner 弱学习器：优于随机猜测；常用 decision stump（单次分裂的浅树）。模型越准，通常 α 越大；错分噪声也可能被不断放大。

04 Gradient Boosting / 学习负梯度

For squared-error regression 平方损失回归：

$F_0(x)=\text{mean}(y)$
 $r_{im}=y_i-F_{m-1}(x_i)$
 Train h_m to predict r_{im}
 $F_m(x)=F_{m-1}(x)+\eta h_m(x)$

Residual 残差 = 真实值 - 当前预测。

加回的是树预测的残差，而不是真实残差。

General GB fits negative loss gradients.

一般形式拟合损失的负梯度；分类通常更新分数，再用 sigmoid / softmax 转概率。

手算 / One boosting step

$y=1400$ ， $FID=1000$ ，真实残差=400。
 若新树 $h=350$ 、 $\eta=.1$ ，则 $F_{\text{新}}=1035$ ，
 新残差= $1400-1035=365$ 。

05 Bagging vs Boosting

Bagging	Boosting
Independent 独立训练	Sequential 轮次前后依赖
Average / vote 平均/投票	Add corrections 累加修正
Different trees parallel 不同树可并行	Rounds sequential 轮次串行，树内部可并行
Mainly reduces variance 主要降低方差	Often reduces bias; may overfit 可降低偏差，也可能过拟合

06 提升树变体 / Boosted-tree variants

XGBoost：一、二阶导数（Hessian）近似损失；叶数与叶值正则化；行列采样、稀疏处理、树内部并行。

Objective = $\sum_i \ell(y_i, \hat{y}_i) + \sum_m \Omega(f_m)$
 $\Omega(f) = \gamma T + (\lambda/2) \sum_{j=1}^T w_j^2$

T =叶数； w_j =叶预测值（不是样本权重）。

γ discourages more leaves； λ discourages extreme leaf values. 抑制复杂树和极端叶值。

LightGBM：histogram 直方图分裂；leaf-wise 优先拆收益最大叶；GOSS 保留大梯度、抽样小梯度并重加权；EFB 打包互斥稀疏特征。

CatBoost：ordered target encoding 仅用随机排列中此前同类样本统计，配合平滑；ordered boosting 减少 prediction shift；symmetric trees 同一层使用同一分裂规则。