CS5234 Mock Quiz 1

解答

A 部分 · 模拟测验（20 分）

Problem 1（7 分）· 估计数组之和

可查询数组 $a_1, \dots, a_n$，每个 $a_i \in \{1, 2, \dots, M\}$。令 $S = \sum_i a_i$。

(a) [2] 设计一个只用 1 次查询、满足 $\mathbb{E}[X] = S$ 的估计量 X。

解答. 均匀随机选 $I \in [n]$，查询 a_I，输出 $X = n\,a_I$。则 $\mathbb{E}X = \sum_i \frac{1}{n} \cdot n a_i = S$。

(b) [3] 证明 $\mathrm{Var}(X) \le MS^2$，并说明取 $k = O(M/\varepsilon^2)$ 份独立副本的平均即可使 $\Pr[|\bar{X} - S| \le \varepsilon S] \ge 2/3$。提示：用 $a_i \le M$ 上界 $\mathbb{E}[X^2]$，再用 $S \ge n$。

解答. $\mathbb{E}X^2 = \sum_i \frac{1}{n} n^2 a_i^2 = n \sum_i a_i^2 \le n \sum_i M a_i = nMS$。因每个 $a_i \ge 1$，$S \ge n$，故 $\mathrm{Var}X \le \mathbb{E}X^2 \le nMS \le MS^2$。$k$ 份独立副本的平均 $\bar{X}$ 满足 $\mathbb{E}\bar{X} = S$，$\mathrm{Var}\bar{X} \le MS^2/k$。Chebyshev：$\Pr[|\bar{X} - S| > \varepsilon S] \le \frac{MS^2/k}{\varepsilon^2 S^2} = \frac{M}{k\varepsilon^2}$，取 $k = \lceil 3M/\varepsilon^2 \rceil$ 即 $\le \frac{1}{3}$。评分：$\mathbb{E}X^2$ 1 分，用 $S \ge n$ 1 分，Chebyshev 与 k 1 分。

(c) [2] 如何把成功率提高到 $1 - \delta$？总查询次数是多少？

解答. Median trick：把 (b) 的估计独立跑 t 次，输出 t 个平均值的中位数。中位数偏差超过 εS 必须至少 $t/2$ 次在同侧失败；每次失败概率 $\le 1/3$，由 Chernoff 概率 $\le 2e^{-t/100}$。取 $t = \lceil 100 \ln(2/\delta) \rceil = O(\log \frac{1}{\delta})$。总查询 $t \cdot k = O\big(\frac{M}{\varepsilon^2} \log \frac{1}{\delta}\big)$。

Problem 2（7 分）· 0 个 1 还是 k 个 1

输入 $x \in \{0,1\}^n$ 保证要么全为 0，要么恰有 k 个 1（$1 \le k \le n/2$）。判断是哪一种，成功率至少 $2/3$。

(a) [2] 给出 $O(n/k)$ 次查询的随机算法并分析。

解答. 均匀随机（有放回）查询 $t = \lceil 2n/k \rceil$ 个位置，看到 1 就回答「k 个 1」。全 0 输入永远看不到 1，总是正确。有 k 个 1 时每次查询以 k/n 命中，$\Pr[\text{全部错过}] = (1 - \frac{k}{n})^t \le e^{-tk/n} \le e^{-2} < \frac{1}{3}$。单边错误，$O(n/k)$ 次查询。

(b) [3] 令 μ_0 为全 0，μ_1 在均匀随机的 k 元子集上放 1。对任意 q 次查询的确定性算法，令 ν_0, ν_1 为两种情况下查询-回答记录的分布。证明 $\Delta_{\mathrm{TV}}(\nu_0, \nu_1) \le qk/n$。

解答. 确定性算法在一直收到 0 时沿一条固定路径 P 走，查询固定位置 $p_1, \dots, p_q$；记这个全 0 记录为 τ_0。在 μ_0 下记录恒为 τ_0，ν_0 是单点分布。在 μ_1 下记录与 τ_0 不同，仅当某个 p_j 落在随机 k 集中；每个固定位置落入的概率为 k/n，union bound 得 $\Pr_{\mu_1}[\text{记录} \ne \tau_0] \le qk/n$。故 $\Delta_{\mathrm{TV}}(\nu_0, \nu_1) = \frac{1}{2}\big[(1 - \nu_1(\tau_0)) + \sum_{\tau \ne \tau_0} \nu_1(\tau)\big] = 1 - \nu_1(\tau_0) \le \frac{qk}{n}$. 关键：在看到第一个 1 之前，被查的位置与输入无关，所以可以对这些固定位置做 union bound。

(c) [2] 用 Yao 原理得出 $R(f) = \Omega(n/k)$。这对 NotOR 性质测试（取 $k = \varepsilon n$）意味着什么？

解答. 取 $\mu = \frac{1}{2}\mu_0 + \frac{1}{2}\mu_1$。任意 q 次查询的确定性算法区分两种情况的概率至多 $\frac{1}{2} + \frac{1}{2}\Delta_{\mathrm{TV}} \le \frac{1}{2} + \frac{qk}{2n}$。要正确率 $\ge \frac{2}{3}$ 需 $q \ge \frac{n}{3k}$，故 $D_\mu(f) \ge \frac{n}{3k}$，由 Yao $R(f) = \Omega(n/k)$；结合 (a) 得 $\Theta(n/k)$。NotOR 取 $k = \varepsilon n$：含 εn 个 1 的串离全 0 是 ε-far，任何测试器都必须解决这个问题，所以需要 $\Omega(1/\varepsilon)$ 次查询，与 $O(1/\varepsilon)$ 的测试器匹配。

Problem 3（6 分）· 流式抽取 k 个样本

数据流 $x_1, \dots, x_n \in [m]$ 逐个到达，n 事先未知。算法：存下前 k 个元素；第 i 个元素（$i > k$）到达时，以概率 k/i 替换当前 k 个样本中均匀随机的一个。

(a) [3] 用归纳法证明：处理完第 i 个元素后（$i \ge k$），每个 x_j（$j \le i$）在样本中的概率恰为 k/i。

解答. 基础 $i=k$：前 k 个都在样本中，概率 $1=k/k$。归纳：设第 $i-1$ 步后成立。新元素 x_i 以 k/i 进入。对 $j<i$，x_j 在第 i 步后仍在 ⇔ 之前在（概率 $\frac{k}{i-1}$）且未被替换；被替换需要 x_i 被接受（$\frac{k}{i}$）且恰好选中它的位置（$\frac{1}{k}$），与过去独立。故 $\Pr=\frac{k}{i-1}\left(1-\frac{k}{i}\cdot\frac{1}{k}\right)=\frac{k}{i-1}\cdot\frac{i-1}{i}=\frac{k}{i}$.

(b) [1] 算法需要多少空间?

解答. k 个值各 $\log m$ 位，加上计数器 i 的 $\log n$ 位：$O(k\log m+\log n)$ 位。

(c) [2] 设流中偶数比例为 p，用最终样本中偶数的比例 $\hat{p}$ 估计。可以直接使用「x_j 在样本中」这些指示变量两两非正相关。证明 $k=O(1/\varepsilon^2)$ 时 $\Pr[|\hat{p}-p|\le\varepsilon]\ge 2/3$。

解答. 令 E 为偶数所在位置，$|E|=pn$，$Y_j=\mathbf{1}[x_j$ 在样本中$]$。则 $\hat{p}=\frac{1}{k}\sum_{j\in E}Y_j$，由 (a) 得 $\mathbb{E}\hat{p}=\frac{1}{k}\cdot pn\cdot\frac{k}{n}=p$。协方差非正 $\Rightarrow \mathrm{Var}(\sum_{j\in E}Y_j)\le\sum\mathrm{Var}Y_j\le\sum\mathbb{E}Y_j=pk$，故 $\mathrm{Var}\hat{p}\le\frac{p}{k}\le\frac{1}{k}$。Chebyshev：$\Pr[|\hat{p}-p|>\varepsilon]\le\frac{1}{k\varepsilon^2}\le\frac{1}{3}$，取 $k=\lceil 3/\varepsilon^2\rceil$。（不能直接用 Chernoff：$Y_j$ 不独立。）

B 部分 · 额外练习

E1 · 最大负载（L1）

n 个球独立均匀地投入 n 个箱。(a) 证明以 $1-o(1)$ 的概率，没有箱子收到超过 $10\ln n$ 个球。(b) 为什么这里用 Chebyshev 不够?

解答. (a) 固定箱 j，负载 $X=\sum_i X_i$，$X_i\in\{0,1\}$ 独立，$\mu=1$。Chernoff（$\delta>1$），取 $1+\delta=10\ln n$：$\Pr[X\ge 10\ln n]\le e^{-\delta\mu/3}=e^{-(10\ln n-1)/3}=e^{1/3}n^{-10/3}$。对 n 个箱 union bound：$\le e^{1/3}n^{-7/3}=o(1)$。(b) $\mathrm{Var}X\le 1$，Chebyshev 每个箱只给出 $\frac{1}{(10\ln n-1)^2}$，乘以 n 个箱后 union bound 超过 1。union bound 要求每个箱的尾概率小于 $1/n$，只有指数尾（Chernoff）做得到。

E2 · 相对误差计数（L2）

n 位串中有 A 个 1，已知 $A\ge t$（t 已知）。(a) 用 $O\big(\frac{n}{t\varepsilon^2}\big)$ 次查询以 $2/3$ 的概率给出 A 的 $(1\pm\varepsilon)$ 近似。(b) 若 t 未知（但 $A\ge 1$），给出做法思路。

解答. (a) 有放回抽 k 位，输出 $\hat{A}=X\frac{n}{k}$。$\mu=\mathbb{E}X=\frac{kA}{n}\ge\frac{kt}{n}$。Chernoff 取 $\delta=\varepsilon$：$\Pr[|X-\mu|\ge\varepsilon\mu]\le 2e^{-\varepsilon^2\mu/3}\le 2e^{-\varepsilon^2 kt/(3n)}$。取 $k=\frac{6n}{t\varepsilon^2}$ 即 $2e^{-2}<\frac{1}{3}$。(b) 仿照估计边数的算法猜 $t'=n/2,n/4,\ldots$：用 t' 跑 (a)，估计值第一次 $\ge 2t'$ 时停止。t' 远大于 A 时估计值很小（Chernoff 上尾，用 $\mu_H=kt'/n$）；$t'\le A$ 后估计准确。代价是几何级数，由最后一轮主导，为 $O(\frac{n}{A\varepsilon^2})$；每轮用 median trick 放大，再对 $O(\log n)$ 轮做 union bound。

E3 · 测试串是否为常数（L4）

性质：$x\in\{0,1\}^n$ 的所有位都相同。(a) x 到该性质的距离是多少？(b) 给出一个 $O(1/\varepsilon)$ 次查询的单边测试器并证明其正确。

解答. (a) $\min(\#0,\#1)$：把少数派的位改掉即可。所以 ε-far ⇔ 少数派比例 $m\ge\varepsilon$（$m\le\frac{1}{2}$）。(b) 抽 $k=\lceil 2/\varepsilon\rceil$ 个位置，全部相同则接受。常数串总被接受。若 ε-far，全部相同只能是全为多数派或全为少数派：$\Pr=(1-m)^k+m^k\le 2(1-m)^k\le 2(1-\varepsilon)^k\le 2e^{-2}<\frac{1}{3}$（用了 $m\le 1-m$）。

E4 · 判断三角形需要 $\Omega(n^2)$（L3）

在 n 个顶点的图上用 pair query，证明判断图中是否有三角形的随机查询复杂度为 $\Omega(n^2)$。提示：从 OR 归约，加一个特殊顶点。

解答. 给定 $N=\binom{n-1}{2}$ 位、以点对 $\{i,j\}\subseteq[n-1]$ 编号的 OR 实例，构造顶点 $w,a_1,\ldots,a_{n-1}$ 的图：w 与每个 a_i 相连，a_ia_j 有边当且仅当第 $\{i,j\}$ 位为 1。正确性：若第 $\{i,j\}$ 位为 1，则 w,a_i,a_j 构成三角形；若全为 0，图是星形，没有三角形。模拟：查询 (w,a_i) 直接回答 1，不耗 OR 查询；查询 (a_i,a_j) 花一次 OR 查询（$C=1$）。所以 $R(\text{三角形})\ge R(\mathrm{OR}_N)\ge N/3=\Omega(n^2)$。