T1 · 概率与集中不等式

Q1 · 判定问题的错误率放大

考点参考 MIT 6.889 HW0 · 难度 ★

判定问题的随机算法 A 在每个输入上出错概率至多 $1/4$，运行时间 T。设计出错概率至多 β、时间 $O(T\log(1/\beta))$ 的算法 B，并证明。

解答. 独立运行 A 共 k 次，输出多数答案。设 X 为出错次数，是独立指示变量之和，$\mu=\mathbb{E}X\le k/4$。B 出错仅当 $X\ge k/2$。用 Chernoff 上尾（以 $\mu_H=k/4$ 代替 μ，$\delta=1$）：$\Pr[X\ge k/2]\le e^{-\mu_H/3}=e^{-k/12}$。取 $k=\lceil 12\ln(1/\beta)\rceil$，出错率 $\le\beta$，时间 $O(kT)=O(T\log(1/\beta))$。

Q2 · 集卡问题

考点参考 MIT 6.889 HW0 与 L1 球箱模型 · ★

反复掷一个均匀的 n 面骰子。(a) 证明所有面都出现所需的期望次数为 $nH_n=n\ln n+O(n)$。(b) 证明掷 $2n\ln n$ 次后，所有面都出现的概率至少 $1-1/n$。

解答. (a) 把过程分阶段：阶段 i（$i=0,\dots,n-1$）指已见过恰好 i 个不同面的时段。每次投掷以 $\frac{n-i}{n}$ 的概率结束阶段 i，所以阶段长度服从几何分布，期望 $\frac{n}{n-i}$。由线性性，$\mathbb{E}[\text{总次数}]=\sum_{i=0}^{n-1}\frac{n}{n-i}=n\sum_{j=1}^{n}\frac{1}{j}=nH_n$。(b) 某个固定的面在 $2n\ln n$ 次中都没出现的概率 $(1-\frac{1}{n})^{2n\ln n}\le e^{-2\ln n}=n^{-2}$。对 n 个面 union bound：有面缺失的概率 $\le n\cdot n^{-2}=1/n$。

Q3 · 平均话题标签数

考点参考 NUS CS5234（2019）Tutorial 4 · ★★

推文流中每条推文含 0 到 70 个话题标签。用有放回均匀抽取的 s 条推文，以至少 $2/3$ 的概率把平均标签数 A 估计到加性误差 ε 以内。s 需要多大？若要求误差为 εA 且已知 $A\ge 1$，有何变化？

解答. 设第 j 个样本的标签数为 $Y_j\in[0,70]$，令 $Z_j=Y_j/70\in[0,1]$，独立，均值 $A/70$。$\bar{Y}$ 上加性误差 ε 等价于 $\bar{Z}$ 上加性误差 $\varepsilon/70$。Hoeffding：$\Pr[|\bar{Z}-\frac{A}{70}|\ge\frac{\varepsilon}{70}]\le 2e^{-2s\varepsilon^2/70^2}\le\frac{1}{3}$，取 $s=\frac{70^2\ln 6}{2\varepsilon^2}=O(1/\varepsilon^2)$（常数约 4400）。相对误差：$\sum Z_j$ 的 $\mu=sA/70\ge s/70$；Chernoff 取 $\delta=\varepsilon$ 得 $2e^{-\varepsilon^2\mu/3}\le 2e^{-\varepsilon^2 s/210}\le\frac{1}{3}$，取 $s=\frac{210\ln 6}{\varepsilon^2}\approx\frac{377}{\varepsilon^2}$。正是 A 的下界让相对误差变得便宜。流式实现：用 s 个独立的单元素蓄水池即可得到有放回的样本。

T2 · 查询算法与下界

Q4 · 放大近似算法的成功率

考点参考 MIT 6.889 HW0 · ★

算法 A 以 $3/4$ 的概率输出正数 V 的 $(1+\varepsilon)$ 近似。构造只调用 $O(\log(1/\delta))$ 次 A、以 $1-\delta$ 概率输出 $(1+\varepsilon)$ 近似的算法 B。为什么取平均不行？

解答. 运行 A 共 k 次，输出中位数。输出落在 $[V/(1+\varepsilon),(1+\varepsilon)V]$ 内的称为好的一次。中位数坏 $\Rightarrow$ 至少 $k/2$ 次坏。坏的次数期望 $\le k/4$，由 Chernoff（上尾，$\mu_H=k/4$，$\delta=1$）达到 $k/2$ 的概率 $\le e^{-k/12}$。取 $k=\lceil 12\ln(1/\delta)\rceil$。为什么不能平均：坏的输出可以任意离谱（比如 10^9V），一次就能毁掉平均值；中位数只要求多数是好的。

Q5 · 元素互异需要 $\Omega(n)$

L3–L4 的归约套路 · ★

可查询 $a_1,\dots,a_n$（n 为偶数），精确判断所有值是否互不相同。用从 OR 的归约证明随机查询复杂度为 $\Omega(n)$。

解答. 给定 OR 实例 $b \in \{0,1\}^{n/2}$，令 $a_{2j-1} = 2j-1$；$b_j = 0$ 时 $a_{2j} = 2j$，$b_j = 1$ 时 $a_{2j} = 2j-1$。正确性：唯一可能的重复值出现在第 j 对内部，且当且仅当 $b_j = 1$；所以数组互异 $\Leftrightarrow \mathrm{OR}(b) = 0$。模拟：查 a_{2j-1} 不需要 OR 查询；查 a_{2j} 需要查一次 b_j（$C = 1$）。因此 $R(\text{互异}) \geq R(\mathrm{OR}_{n/2}) \geq \frac{n/2}{3} = \Omega(n)$。

Q6 · 找最大值需要 $\Omega(n)$

Yao 原理用于搜索问题 · ★★

可查询 $a_1, \ldots, a_n$，输出一个最大值所在的下标，正确率 $\geq 2/3$。证明需要 $\Omega(n)$ 次查询。提示：答案不是二元的，但 Yao 原理仍然适用。

解答. 取 μ：除随机位置 P 上为 1 外全为 0；唯一正确答案是 P。固定一个 q 次查询的确定性算法，它在全 0 路径上查询固定位置 $p_1, \ldots, p_q$。若 P 在其中（概率 q/n），可能答对。否则它只看到 0，输出一个固定下标；此时 P 均匀落在 $n-q$ 个未查位置中，猜中概率至多 $\frac{1}{n-q}$。成功率 $\leq \frac{q}{n} + \frac{n-q}{n} \cdot \frac{1}{n-q} = \frac{q+1}{n}$。要 $\geq \frac{2}{3}$ 需 $q \geq \frac{2n}{3} - 1$。Yao 原理的论证不依赖输出是二元的，所以 $R \geq D_\mu = \Omega(n)$。

Q7 · 平均度的加性估计

L2 考点 · ★

在邻接表模型（可查询度数）中，以 $2/3$ 的概率把 n 个顶点的图的平均度 $\bar{d}$ 估计到加性误差 εn 以内。需要多少次查询？为什么同样的做法在稀疏图上做不到 $(1 \pm \varepsilon)$ 近似？

解答. 有放回抽 s 个顶点，对 $d_v/n \in [0,1]$ 取平均。Hoeffding：$s = O(1/\varepsilon^2)$ 即可在缩放后的平均上有加性误差 ε，也就是 $\bar{d}$ 上的 εn。做 $(1 \pm \varepsilon)$ 近似时相对方差可能极大：星形图中 $\bar{d} \approx 2$，但随机顶点只以 $1/n$ 的概率是度为 $n-1$ 的中心，$\mathrm{Var}(d_v)/\bar{d}^2 = \Theta(n)$，Chebyshev 需要 $\Theta(n/\varepsilon^2)$ 个样本；实际上 $o(n)$ 个样本通常根本抽不到中心。L2 通过把每条边记给排名较低的端点来解决，得到 $O(\sqrt{n}/\varepsilon^2)$。

T3 · 性质测试

Q8 · 测试回文串

「far ⇒ 大量证据」通用套路 · ★

若对所有 i 有 $x_i = x_{n+1-i}$，称 $x \in \{0,1\}^n$ 为回文串。(a) x 到回文串的距离是多少？(b) 给出 $O(1/\varepsilon)$ 次查询的单边测试器。

解答. (a) 把位置 i 与 $n+1-i$ 配对，共 $\lfloor n/2 \rfloor$ 对。每个不匹配的对恰好需要改一位，匹配的对不用改，所以距离等于不匹配对的个数 M。(b) 若 x 是 ε-far，则 $M \geq \varepsilon n$，随机一对不匹配的概率 $\geq \frac{\varepsilon n}{n/2} = 2\varepsilon$。随机抽 $k = \lceil 1/\varepsilon \rceil$ 对（每对 2 次查询），发现不匹配就拒绝。回文串总被接受；ε-far 的串被接受的概率 $\leq (1-2\varepsilon)^k \leq e^{-2} < \frac{1}{3}$。

Q9 · 有界度图的连通性测试

考点参考 MIT 6.889 HW1（Goldreich–Ron） · ★★★

图的最大度为 d，以邻接表给出。若需要超过 εdn 次改边才能连通，称其 ε-far。(a) 证明 ε-far 的图有超过 εdn 个连通分量（可以假设总能用一次加边合并两个分量并保持度数上界，必要时先删一条边）。(b) 推出其中超过 $\frac{\varepsilon dn}{2}$ 个分量的顶点数不超过 $\frac{2}{\varepsilon d}$。(c) 给出查询复杂度与 n 无关的单边测试器。

解答. (a) 有 c 个分量时，$c-1$ 次合并（每次 $O(1)$ 次改边，按题设为一次）就能连通，所以 ε-far 要求 $c - 1 > \varepsilon dn$（差常数）。(b) 顶点数超过 $\frac{2}{\varepsilon d}$ 的分量少于 $\frac{\varepsilon dn}{2}$ 个，否则它们的顶点总数超过 n。所以小分量超过 $\varepsilon dn - \frac{\varepsilon dn}{2} = \frac{\varepsilon dn}{2}$ 个。(c) 小分量里的顶点总数超过 $\frac{\varepsilon dn}{2}$，所以随机顶点落在小分量中的概率 $> \frac{\varepsilon d}{2}$。抽 $s = \lceil \frac{4}{\varepsilon d} \rceil$ 个顶点，从每个出发做 BFS，直到找到 $\frac{2}{\varepsilon d} + 1$ 个顶点或把分量走完。若某次 BFS 走完了一个顶点数少于 n 的分量就拒绝。连通图永远不会被拒绝。对 ε-far 的图，所有样本都不落在小分量里的概率 $\leq (1 - \frac{\varepsilon d}{2})^s \leq e^{-2}$。每次 BFS 探索 $O(\frac{1}{\varepsilon d})$ 个顶点、每个最多 d 次查询，总计 $O\big(\frac{1}{\varepsilon^2 d}\big)$，与 n 无关。

Q10 · 分布之间的距离

考点参考 L4 与 MIT 6.889 HW3 · ★★

(a) 证明 $\Delta_{\mathrm{TV}}(\mu,\nu)=\max_{A\subseteq[n]}|\mu(A)-\nu(A)|$。(b) μ 为 $[n]$ 上的均匀分布，ν 为某个固定集合 S（$|S|=n/4$）上的均匀分布。计算 $\Delta_{\mathrm{TV}}(\mu,\nu)$ 与 $\|\nu\|_2^2$。(c) L4 的碰撞测试器大约需要多少样本才能区分二者？

解答. (a) 令 $A^*=\{i:\mu(i)>\nu(i)\}$。对任意 A，$\mu(A)-\nu(A)\le\sum_{i\in A\cap A^*}(\mu(i)-\nu(i))\le\mu(A^*)-\nu(A^*)$；$\nu(A)-\mu(A)$ 同理，用补集。由于两者总和都为 1，$\mu(A^*)-\nu(A^*)=\nu(\bar{A^*})-\mu(\bar{A^*})=\frac12\sum_i|\mu(i)-\nu(i)|$。(b) 取 $A=S$：$\nu(S)-\mu(S)=1-\frac14=\frac34$，故 $\Delta_{\mathrm{TV}}=\frac34$。$\|\nu\|_2^2=\frac{n}{4}\cdot(\frac4n)^2=\frac4n$，是均匀分布 $\frac1n$ 的 4 倍。(c) 两者的碰撞概率相差常数倍，把 $\|\cdot\|_2^2$ 估到常数精度即可：需要 $\Theta(\sqrt{n})$ 个样本（光是看到一次碰撞就大约要 $\sqrt{n}$ 个）。

T4 · 流式算法

Q11 · Morris++

考点参考 NUS CS5234（2019）Tutorial 4 · ★★

利用 Morris 计数器（无偏，Var $<A^2$），设计一个以 $1-\delta$ 概率输出 $\hat{A}\in[(1-\varepsilon)A,(1+\varepsilon)A]$ 的流式算法。空间是多少？

解答. Morris+：平均 $t=\lceil 3/\varepsilon^2\rceil$ 个独立计数器；Var $<A^2/t$，Chebyshev 得 $\Pr[|\bar{A}-A|>\varepsilon A]<\frac{1}{t\varepsilon^2}\le\frac13$。Morris++：独立跑 $m=O(\log(1/\delta))$ 份 Morris+，取中位数；由 median trick 失败率 $\le\delta$。每个计数器存 $C\approx\log A$，即 $O(\log\log n)$ 位（超过 $O(\log n)$ 的计数器可以截断，这种情况概率极小）。总空间 $O\big(\frac{1}{\varepsilon^2}\log\frac1\delta\log\log n\big)$ 位。

Q12 · 带权蓄水池抽样

L5 蓄水池抽样的经典变形 · ★★

元素 $x_1,x_2,\ldots$ 依次到达，带正权重 $w_1,w_2,\ldots$。只保留一个元素，使结束时 x_i 被保留的概率为 w_i/W_n，其中 $W_i=\sum_{j\le i}w_j$。给出算法并证明。

解答. 维护 W 和当前样本。x_i 到达时，更新 $W\leftarrow W_i$，并以 w_i/W_i 的概率用 x_i 替换样本。证明：x_i 在第 i 步被选中的概率 $\frac{w_i}{W_i}$，在第 $j>i$ 步存活的概率 $1-\frac{w_j}{W_j}=\frac{W_{j-1}}{W_j}$。连乘相消：$\frac{w_i}{W_i}\cdot\frac{W_i}{W_{i+1}}\cdots\frac{W_{n-1}}{W_n}=\frac{w_i}{W_n}$。权重全为 1 时就是 L5 的算法。空间：一个样本加一个累加和。

Q13 · 流中的环与 spanner

L5 考点 · ★★

n 个顶点的图的边以流的形式到达。(a) 用 $O(n\log n)$ 位判断图中是否有环。(b) 用 $k=2$ 的贪心 spanner，证明输出 H 没有长度 ≤4 的环，且 $d_H(u,v)\le3\,d_G(u,v)$。(c) 为什么 $|E(H)|=O(n^{3/2})$？

解答. (a) 用并查集维护生成森林。图有环 $\Leftrightarrow$ 某条到来的边连接了森林中已连通的两点，此时报告有环。森林至多 $n-1$ 条边，空间 $O(n\log n)$ 位。(b) 只有不在 H 中闭合长度 ≤4 的环的边才会被加入；之后加入的边也不能与早先的边构成这样的环（否则闭合它的正是那条后来的边），所以 H 的围长 ≥5。被拒绝的边 (u,v) 闭合了长度 ≤4 的环，说明 H 中已有长度 ≤3 的 u–v 路径。把 G 中 u–v 最短路的每条边都替换成这样的路径，得 $d_H\le3d_G$。(c) 由 L5 引理（$k=2$）：围长 $>4\Rightarrow$ 从任一点出发的 BFS 前两层是树，$(d_{\min}-1)^2\le n$；通过删去低度顶点推广到平均度，得 $|E(H)|=O(n^{1+1/2})=O(n^{3/2})$。