CS5234 Quiz 1 · Mock Paper

解答与评分

格式（按老师公布的要求）：50 分钟 · 开卷 · Lecture 1–5 · 4 道选择题（每题 1 分）+ 2 道大题（9 + 7 分）· 大题留空得 1 分。

第一部分 · 选择题（4 × 1 分）

选择题 1（L1）

设 $X_1, \dots, X_k$ 两两独立，均服从 Bernoulli(p)，$X = \sum_i X_i$。下列哪项一定成立？

(A) $\mathrm{Var}(X) = kp(1-p)$

(B) 当 $0 < \delta \le 1$ 时 $\Pr(|X - kp| \ge \delta kp) \le 2e^{-\delta^2 kp/3}$

(C) $\mathbb{E}[X^2] = k^2p^2$

(D) X 与 X_1 独立

解答. **(A)**。两两独立 ⇒ 协方差全为 0，方差可加：$\mathrm{Var}X = \sum \mathrm{Var}X_i = kp(1-p)$。(B) 是 Chernoff，需要完全独立。(C) 漏了方差：$\mathbb{E}X^2 = \mathrm{Var}X + (\mathbb{E}X)^2 = kp(1-p) + k^2p^2$。(D) 错，$X$ 里包含 X_1。

选择题 2（L2）

某估计量以 0.6 的概率落在真值 A 的 εA 范围内。要使独立重复后的中位数以 $1-\delta$ 的概率落在 εA 范围内，需要多少次重复？

(A) $\Theta(1/\delta)$

(B) $\Theta(\log(1/\delta))$

(C) 做不到，因为 $0.6 < 2/3$

(D) $\Theta(1/\delta^2)$

解答. **(B)**。Median trick 只要求单次成功率严格大于 $1/2$：中位数出错必须至少一半的运行在同侧出错，由 Chernoff 概率为 $e^{-\Omega(k)}$（Ω 里的常数取决于 $0.6 - 0.5$）。$2/3$ 只是“常数成功率”的惯例写法，不是门槛。

选择题 3（L3）

关于 Yao 原理，下列哪项正确？

(A) 对任意输入分布 μ，$D_\mu(f) \ge R(f)$

(B) 要证 $R(f) \ge q$，只需找到一个分布 μ 使 $D_\mu(f) \ge q$

(C) 它只适用于答案为 0/1 的问题

(D) 难分布必须是全体输入上的均匀分布

解答. **(B)**。Yao 原理给出对任意 μ 都有 $D_\mu(f) \le R(f)$，所以 (A) 方向反了，(B) 由此直接得到。平均论证不依赖输出是二元的，搜索问题（比如找最大值）同样适用，(C) 错。OR 的难分布是“$\frac{1}{2}$ 全 0 + $\frac{1}{2}$ 一个随机的 1”，远不是均匀分布，(D) 错。

选择题 4（L4）

测试 n 个互异数组成的数组是否有序（ε-far 指需要改动超过 εn 项），下列哪个测试器在 $O(\log n/\varepsilon)$ 次查询下是正确的？

(A) 随机选 $O(1/\varepsilon)$ 个 i，检查 $a_i \le a_{i+1}$

(B) 随机选 $O(1/\varepsilon)$ 个下标，按下标排序后检查取值递增

(C) 随机选 $O(1/\varepsilon)$ 个下标，对每个值做一次二分搜索

(D) 都不行：任何测试器都需要 $\Omega(n)$ 次查询

解答. **(C)**。(A) 栽在 $7,8,\dots,12,1,\dots,6$：它是 $\frac{1}{2}$-far，却只有一个相邻逆序。(B) 栽在 $2,1,4,3,\dots$：必须同时抽中交换的一对，约需 $\sqrt{n}$ 个样本。(D) 只对精确判定成立，测试可以做到次线性。(C) 正确：二分搜索成功的下标彼此有序，所以 ε-far 的数组至少有 εn 个失败下标。

第二部分 · 大题

大题 1（9 分）· 数相等的对

可查询数组 $a_1,\dots,a_n$。令 $N=\binom{n}{2}$，P 为满足 $a_i=a_j$ 的对 $i<j$ 的个数。

(a) [2] 用两次查询给出 P 的无偏估计。

解答. 在 N 个对中均匀选一对 $\{i,j\}$，查询 a_i,a_j，输出 $X=N\cdot\mathbf{1}[a_i=a_j]$。则 $\mathbb{E}X=N\cdot\frac{P}{N}=P$。评分：估计量 1 分，期望计算 1 分。

(b) [3] 用 $O(\varepsilon^{-2}\log(1/\delta))$ 次查询，以 $1-\delta$ 的概率把 P 估计到加性误差 εN 以内。

解答. 取 k 个独立的对；令 $Y_t=\mathbf{1}[$第 t 对相等$]\in\{0,1\}$，独立，均值 $\rho=P/N$，输出 $\hat{P}=N\cdot\frac{1}{k}\sum_t Y_t$。误差 $\le\varepsilon N\Leftrightarrow|\bar{Y}-\rho|\le\varepsilon$。Hoeffding：$\Pr[|\bar{Y}-\rho|>\varepsilon]\le 2e^{-2k\varepsilon^2}\le\delta$，取 $k=\lceil\ln(2/\delta)/(2\varepsilon^2)\rceil$；查询 $2k=O(\varepsilon^{-2}\log(1/\delta))$ 次。（等价做法：仿照 L2 计数用 Chernoff 取 $k=O(1/\varepsilon^2)$ 得到 $2/3$，再用 median trick 重复 $O(\log(1/\delta))$ 次。）评分：写明独立 1 分，不等式用对 1 分，最终 k 与查询次数 1 分。

(c) [4] 现在要精确判断 $P=0$ 还是 $P\ge 1$，成功率 $\ge 2/3$。证明需要 $\Omega(n)$ 次查询。提示：令 μ_0 为对所有 i 有 $a_i=i$；μ_1 把 a_1 复制到一个随机位置。

解答. 难分布（1 分）：μ_0：$a_i=i$，$P=0$。μ_1：在 $\{2,\dots,n\}$ 中均匀选 J，令 $a_J=1$，其余 $a_i=i$，$P=1$。均匀抽 $I\in\{0,1\}$，再抽 $a\sim\mu_I$。记录分布（2 分）：固定一个 q 次查询的确定性算法。只要每次回答都是 $a_i=i$，它就沿一条固定路径走，查询固定位置 $p_1,\dots,p_q$；记这个记录为 τ_0。μ_0 下记录恒为 τ_0；μ_1 下记录与 τ_0 不同，仅当 $J\in\{p_1,\dots,p_q\}$，概率 $\le\frac{q}{n-1}$。故 $\Delta_{\mathsf{TV}}(\nu_0,\nu_1)=1-\nu_1(\tau_0)\le\frac{q}{n-1}$。结论（1 分）：成功率至多 $\frac{1}{2}+\frac{1}{2}\Delta_{\mathsf{TV}}\le\frac{1}{2}+\frac{q}{2(n-1)}$，要达到 $\frac{2}{3}$ 需 $q\ge\frac{n-1}{3}$。故 $D_\mu\ge\frac{n-1}{3}$，由 Yao 得 $R=\Omega(n)$。注：这与 (b) 不矛盾，因为 $\varepsilon N=\Theta(\varepsilon n^2)$ 的加性误差区分不了 $P=0$ 和 $P=1$。

大题 2（7 分）· 流中的相邻重复

数据流 $x_1,\dots,x_n\in[m]$ 逐个到达，n 事先未知。令 $R=|\{i\le n-1:x_i=x_{i+1}\}|$，$\rho=R/(n-1)$。要以至少 $2/3$ 的概率输出满足 $|\hat{\rho}-\rho|\le\varepsilon$ 的 $\hat{\rho}$。

(a) [3] 设计一个流式算法。提示：用蓄水池抽样选一个均匀随机的位置 $I\in[n-1]$，但你还需要 x_{I+1}。

解答. 用一个字的缓冲区记住前一个元素。独立运行 k 份如下过程：x_i 到达时（$i\ge 2$），位置 $i-1$ 成为候选，以概率 $\frac{1}{i-1}$ 把存的对替换为 (x_{i-1},x_i)（x_{i-1} 取自缓冲区）。由 L5 在位置 $1,\dots,n-1$ 上的蓄水池论证，结束时每份都存着 (x_I,x_{I+1})，I 在 $[n-1]$ 上均匀。输出 $\hat{\rho}=\frac{1}{k}\sum_t\mathbf{1}[$第 t 份存的是相等对$]$。评分：缓冲区思路 1 分，替换概率正确 1 分，输出 1 分。

(b) [2] k 需要多大？给出理由。

解答. 各份的指示变量 Z_t 相互独立（独立副本），均值都是 $\Pr[x_I=x_{I+1}]=\rho$。Hoeffding：$\Pr[|\hat{\rho}-\rho|>\varepsilon]\le 2e^{-2k\varepsilon^2}\le\frac{1}{3}$，取 $k=\lceil\ln 6/(2\varepsilon^2)\rceil=O(1/\varepsilon^2)$。（用 Chebyshev 也行：$\mathrm{Var}\hat{\rho}\le\frac{1}{4k}$，取 $k=\frac{3}{4\varepsilon^2}$。）

(c) [1] 空间复杂度是多少？

解答. k 个存储的对（每个 $2\log m$ 位）、一个缓冲区（$\log m$ 位）和位置计数器（$\log n$ 位）：共 $O(\varepsilon^{-2}\log m+\log n)$ 位。

(d) [1] 为什么不能简单地存下流中前 k 个相邻对？

解答. 前 k 个位置不是随机样本。对手可以把所有重复都放在第 k 个位置之后（比如先 $1,2,\dots,n/2$，再接 $n/2$ 个相同的值）：此时 $\rho\approx\frac{1}{2}$，但前 k 个对里没有重复，估计值为 0。集中不等式要求每个样本在所有位置上均匀。