CS5234 Quiz 2 · Cheat Sheet

第 5、7–10 讲 · 11 月 5 日 LT12 · 开卷 · log = ln

0 · 题型识别 → 工具

- **流式上界**: 维护 sketch / 样本 / 摘要；无偏估计 → 方差 → Chebyshev（mean trick）→ median trick
- **流式下界**: 单向通信；从 Index / Gap-Hamming / Disjointness 归约；把 Bob 的下标编码成关键边/元素
- **允许删除（turnstile）**: 用线性 sketch Rx
- **极小内存计数**: Morris：只存计数的对数；mean trick
- **量级未知**: 转成带阈值 T 的测试问题，并行跑 $T=(1+\varepsilon)^j$
- **图流**: 维护稀疏子图（森林 / spanner），证明不变量 + 边数上界
- **需要多少独立性** 只用 Chebyshev → 两两独立；四阶矩（AMS）→ 4-wise；以 k 个大项为条件 → $(k+2)$-wise

1 · 工具回顾

- Markov $\Pr(X\ge t)\le \mathbb{E}X/t$; Chebyshev $\Pr(|X-\mathbb{E}X|\ge t)\le \mathrm{Var}X/t^2$
- k 份平均: Var/k; 需 $k=\frac{3\mathrm{Var}X}{\varepsilon^2(\mathbb{E}X)^2}$ 得 2/3
- Chernoff (独立, $[0,1]$): $\Pr(|X-\mu|\ge\delta\mu)\le 2e^{-\delta^2\mu/3}$
- Median trick：成功率 $>\frac12\to O(\log\frac1\delta)$ 份；对 m 项 union bound 取 $\delta=1/m^2$
- $\{0,1\}$ 变量: Var $\le\mathbb{E}$; 两两独立 ⇒ 方差可加
- $(1-\frac1T)^T\approx\frac1e, (1-\frac1T)^{2T}\le\frac{1}{e^2}$; $\frac{d^k}{k!}\le(\frac{ed}{k})^k$

2 · L5 流式基础

模型 元素逐个到达、只看一次；内存最好是 polylog(n)；存一个元素 $\log m$ 位，一个计数器 $\log n$ 位。

蓄水池抽样 存 x；x_i 到达时以概率 $\frac1i$ 替换。$\Pr[\text{最终}=x_i]=\frac1i\cdot\frac{i}{i+1}\cdots\frac{n-1}{n}=\frac1n$. 空间 $\log m+\log n$. k 份独立副本 ⇒ k 个有放回样本。

Morris 计数器 每来一个 1，以概率 2^{-C} 令 $C\leftarrow C+1$；输出 2^C-1。
$X_i=2^{C_i}$: $\mathbb{E}[X_{i+1}\mid X_i{=}x]=2x\cdot\frac1x+x(1-\frac1x)=x+1\Rightarrow\mathbb{E}X_A=A+1$ (无偏).
$\mathbb{E}[X_{i+1}^2\mid x]=x^2+3x\Rightarrow\mathbb{E}X_i^2=\frac{3i(i+1)}{2}+1$, $\mathrm{Var}X_A=\frac{A(A-1)}{2}<A^2$.
取 $\frac{10}{\varepsilon^2}$ 份平均：Var $<\frac{\varepsilon^2A^2}{10}$ ⇒ Chebyshev 失败率 $<\frac1{10}$。空间 $O(\varepsilon^{-2}\log\log n)$（$C$ 约为 $\log n$）。**关键：全期望公式 + 递推。**

边流 顶点集事先已知，边逐条到达。

连通性 维护生成森林 F：加入 e 不成环就加。至多 $n-1$ 条边 ⇒ $O(n\log n)$ 位；G 连通 ⇔ F 连通。

二分图 二分图 ⇔ 无奇环。维护森林 F；$F\cup e$ 有奇环 → 答 No；无环 → 加入。正确性：答 Yes ⇒ 给森林 2-染色；每条 $e\notin F$ 都闭合偶环 ⇒ 两端异色 ⇒ 对 G 也合法。

$(2k-1)$-spanner $H\subseteq G$ 且 $d_G\le d_H\le(2k-1)d_G$。加入 $e=(u,v)$ 当且仅当不形成长度 $\le 2k$ 的环（即 $d_H(u,v)>2k-1$）。
伸缩：被拒的边已有 $d_H(u,v)\le 2k-1$；把最短路上每条边替换掉 ⇒ $d_H\le(2k-1)d_G$。
大小：围长 $>2k$ ⇒ $O(n^{1+1/k})$ 条边。(i) 最小度 δ：BFS 前 k 层是一棵树，点数 $\ge(\delta-1)^k\le n$ ⇒ $\delta=O(n^{1/k})$。(ii) 平均度 d ⇒ 反复删度 $<\frac{d}{4}$ 的点（删掉 $<\frac{m}{2}$ 条边）⇒ 剩下子图最小度 $\ge\frac{d}{4}$ ⇒ $d=O(n^{1/k})$。

空间 $O(n^{1+1/k}\log n)$ 位。$k=2$: 3-spanner，$O(n^{3/2})$ 条边。

3 · L7 不同元素计数

测试 $h:[m]\to[T]$；Pr[无元素映到 1] $=(1-\frac1T)^{DE}$：$DE\le T$ 时 $\approx\frac1e$，$DE\ge 2T$ 时 $\le\frac{1}{e^2}$。跑 $O(1)$ 份，阈值 $\frac12(\frac1e+\frac{1}{e^2})$，Chernoff。猜 $T=(1+\varepsilon)^j\Rightarrow(2+2\varepsilon)$。完全随机 h 要 $m\log T$ 位。

KMV $h:[m]\to[m], t=\frac{100}{\varepsilon^2}$, $X=t$-小哈希值, 输出 $\widetilde{DE}=\frac{tm}{X}$.
低估 ⇔ 低于 $\frac{tm}{(1-\varepsilon)DE}$ 的哈希值少于 t 个；$Y=\sum Y_i$，$\mathbb{E}Y=\frac{t}{1-\varepsilon}$，$\mathrm{Var}Y\le\mathbb{E}Y$（两两独立）⇒ Chebyshev $\le\frac1{10}$；高估同理；union ⇒ 0.8；median ⇒ $1-\delta$。空间 $O(\varepsilon^{-2}\log m\log\frac1\delta)$. **!删除时失效**

k-wise 独立哈希
$\Pr[h(x_1){=}y_1,\dots,h(x_k){=}y_k]=m^{-k}$（$x$ 互异）. $h(x)=\sum_{j<k}c_jx^j$ over $\mathbb{F}_m$ (m 质数). 证明：在 k 点上取值相同的两个多项式之差次数 $\le k-1$ 却有 k 个根 ⇒ 相等；m^k 个多项式与 m^k 组输出一一对应。空间 $O(k\log m)$.

4 · L8 通信复杂度

流式 → 单向通信 Alice 跑前半段，把内存（S 位）发给 Bob，Bob 接着跑。通信下界 C ⇒ 空间 $\ge C$。

Equality 确定性 $\ge n$：$\le n-1$ 位 ⇒ 消息 $\le 2^{n-1}<2^n$ 个输入 ⇒ 两输入同消息，Bob 取 $y=x_1$ 必错其一。随机：发 $r\cdot x \bmod 2$，$x\ne y$ 以 $\frac12$ 被发现，重复 $\log\frac1\delta$ 次；需公共 r。

Newman 公共随机 → 私有随机，多 $O(\log n+\log\frac1\delta)$ 位、错误 $+\delta$：固定 $t=100n/\delta^2$ 个串；每个输入 Chernoff（$<2^{-10n}$）+ 对 2^{2n} 个输入 union；Alice 发编号 i。

已知难题 Index (x / $i\to x_i$): $\Omega(n)$. Gap-Hamming (Hamming 距离 $\pm\sqrt{n}$): $\Omega(n)$.

归约 A 难（C），额外发 $|M|$ ⇒ B 至少 $C-|M|$。

交集大小 $\pm\frac{\sqrt n}{2}$: Ham $=|X|+|Y|-2|X\cap Y|$, 发 $|X|$ ⇒ $\Omega(n)$.

不相交：$X=\{j:x_j=1\}$, $Y=\{i\}$ ⇒ $\Omega(n)$。

图流 连通性 $\Omega(n)$：$x_j=1$ 则连 u_A-v_j（Alice）；u_B 连所有 $v_{j\ne i}$ 及 u_A（Bob）⇒ 连通 ⇔ $x_i=1$。完美匹配 $\Omega(n^2)$：n^2 位 Index 编成二分图 u_i-v_j；Bob 给 $u_{i\ne i^*}$、$v_{j\ne j^*}$ 各挂专属替身 ⇒ 有完美匹配 ⇔ $u_{i^*}v_{j^*}$ 有边。MIS $\Omega(n^2)$（两份副本 + 特殊点）。

5 · L9 频率估计

频率矩 $F_p=\sum f_i^p$; F_0=不同元素数, F_1=流长. 碰撞抽样需 $\Theta(\sqrt{n}/\varepsilon^2)$，太多。

AMS (F_2) $p_i\in\{\pm1\}$, $Z=\sum p_if_i$ (更新 $Z{+}{=}p_x\Delta$), 输出 Z^2.
$\mathbb{E}Z^2=\sum f_i^2$ (交叉项为 0); $\mathbb{E}Z^4=\sum f_i^4+3\sum_{i\ne j}f_i^2f_j^2\le 3F_2^2\Rightarrow\mathrm{Var}Z^2\le 2F_2^2$. 平均 $30/\varepsilon^2$ 份 ⇒ Chebyshev $\le\frac1{10}$。符号 4-wise 独立。空间 $O(\varepsilon^{-2}(\log m+\log n))$。

模型 $\Delta=1$ 频率; $\Delta\ge0$ cash register; 任意 turnstile; $x_i\ge0$ 始终 strict turnstile.

线性 sketch 维护 $y=Rx$；更新 $y\mathrel{+}{=}\Delta Re_i$ ⇒ 天然支持删除。AMS 可以，KMV 不行。F_p $(p>2)$：$\tilde\Theta(m^{1-2/p})$。

Misra-Gries $\le k$ 个计数器；在表里 $+1$；没满就加入；满了全体 -1，删 0。“全体减 1” $\le n/k$ 次 ⇒ $x_i-\frac{n}{k}\le c_i\le x_i$。$k=1/\varepsilon$：误差 εn，确定性，只加不减，非线性。（过半数：一对 (i,c)。）

Count-Min t 行 $\times k$; $C_\ell[h_\ell(i)]\mathrel{+}{=}\Delta$; $\tilde x_i=\min_\ell$. 多算期望 $\le\|x\|_1/k$; $k=2/\varepsilon$ + Markov ⇒ 单行坏 $<\frac12$; $t=2\log_2 m$ ⇒ $1/m^2$; union ⇒ 对所有 i 成立。只适用 strict turnstile；两两独立哈希。

Count Sketch 再加 $g_\ell:[m]\to\{\pm1\}$; $Y_{\ell,i}=g_\ell(i)C_\ell[h_\ell(i)]$：无偏，Var $\le\|x\|_2^2/k$; $k=10/\varepsilon^2$ ⇒ 0.9; $t=100\log m$ 行取中位数 ⇒ $|\tilde x_i-x_i|\le\varepsilon\|x\|_2$。任意 turnstile。
ℓ_1 大户 → Count-Min; ℓ_2 大户 → Count Sketch。

稀疏恢复 $\|x\|_0\le k$: 下界 $\Omega(k(\log m+\log n))$. 1-稀疏：值 $=\sum\Delta$；位置第 b 位 = [第 b 位为 1 的下标之和 >0]（二分）。一般：随机 0/1 向量 r 以 $\ge\frac12$ 区分 $x\ne y$；固定 $O(k(\log m+\log n))$ 个 r（指数时间）。

6 · L10 数据压缩

近似稀疏恢复 $\mathrm{err}_2^k(x)=\min_{\|z\|_0\le k}\|z-x\|_2$ (保留最大 k 项). Count Sketch, $S=\frac{10k}{\varepsilon^2}$, $t=100\log m$; 保留 x' 最大 k 项。
第 1 步：不撞 k 个大项的概率 $\ge1-\frac{\varepsilon^2}{10}$；此时 Var $\le\mathrm{err}^2/S\Rightarrow|x'_i-x_i|\le\frac{\varepsilon}{\sqrt k}\mathrm{err}$（$(k+2)$-wise）。
第 2 步：I 选中、J 真大项；漏掉的 j 被冒牌 i 挤掉：$|x_j|\le|x_i|+\frac{2\varepsilon}{\sqrt k}\mathrm{err}$ ⇒ 总 $\le(1+9\varepsilon)\mathrm{err}^2\Rightarrow(1+5\varepsilon)\mathrm{err}$。空间 $O(\varepsilon^{-2}k\log m(\log n+\log m))$.

JL $\Pi_{ij}\sim\mathcal{N}(0,1)$, $k=\frac{\alpha}{\varepsilon^2}\log\frac1\delta$: $\|\frac{1}{\sqrt k}\Pi x\|_2=(1\pm\varepsilon)\|x\|_2$ w.p. $1-\delta$ (与 m 无关). $y_i\sim\mathcal{N}(0,\|x\|_2^2)$; $\Pr[(1-\varepsilon)^2k\le\sum z_i^2\le(1+\varepsilon)^2k]\ge1-2e^{-c\varepsilon^2k}$. n 个点：$\delta=\frac{1}{10n^2}$ + union ⇒ $k=O(\frac{\log n}{\varepsilon^2})$。

线性回归 $L(x)=\|Ax-b\|_2=\|My\|_2$, $M=[A,b]$, $y=(x,-1)$. 若对所有 y 有 $\|\Phi My\|=(1\pm\frac{\varepsilon}{10})\|My\|$：$(1-\frac{\varepsilon}{10})L(\tilde x)\le\tilde L(\tilde x)\le\tilde L(x^*)\le(1+\frac{\varepsilon}{10})L(x^*)\Rightarrow(1+\varepsilon)$.

子空间嵌入 d-维 E, $k=O(\frac{d+\log(1/\delta)}{\varepsilon^2})$ ⇒ 所有 $x\in E$ 被保持. 只看单位向量；$\frac12$-net 大小 $\le5^d$（半径 $\frac\gamma2$ 小球互不相交、都在半径 $1+\frac\gamma2$ 大球内）；对网上的点及差用 JL（$2^{O(d)}$ 个事件）⇒ 内积也保持；$x=\sum z_i$, $\|z_i\|\le2^{1-i}$, $\sum\|z_i\|\le2$ ⇒ 误差 $O(\varepsilon)$。压缩后 $\tilde O(d^2/\varepsilon^2)$ 个数。

7 · 易错点

- 哈希函数是固定的：重复元素落进同一格（所以哈希统计的是不同元素）。
- 写明分析需要的独立性（两两 / 4-wise / $(k+2)$-wise），并计入空间。
- Count-Min 要求 $x_i \geq 0$；Misra-Gries 只能加；KMV 遇删除失效。
- Morris：$\mathbb{E}[2^C] = A+1$ 不是 A，要输出 $2^C - 1$；每份空间是 $\log\log n$ 不是 $\log n$。
- 下界归约：两个方向都要验证（答案 $\Leftrightarrow$ $x_i = 1$），且 Alice 的部分只依赖 x、Bob 的只依赖 i。
- 对“所有 i/所有输入”做 union bound：单项失败率必须远小于 1/项数。

8 · 各 sketch 对比

算法	模型	保证	空间
KMV	只插入	$(1\pm\varepsilon)DE$	$\varepsilon^{-2}\log m$
AMS	任意	$(1\pm\varepsilon)F_2$	$\varepsilon^{-2}\log(mn)$
M-G	只插入	$-\varepsilon n$, 确定	$\varepsilon^{-1}\log(mn)$
CM	strict	$+\varepsilon\|x\|_1$	$\varepsilon^{-1}\log m\log(mn)$
CS	任意	$\pm\varepsilon\|x\|_2$	$\varepsilon^{-2}\log m\log(mn)$
JL	线性	$(1\pm\varepsilon)\|x\|_2$	$\varepsilon^{-2}\log\frac{1}{\delta}$ 行
Morris	只插入	$(1\pm\varepsilon)A$	$\varepsilon^{-2}\log\log n$
Spanner	边流	伸缩 $2k-1$	$n^{1+1/k}\log n$

KMV/AMS 要 $1-\delta$ 再乘 $\log\frac{1}{\delta}$。M-G = Misra-Gries，CM = Count-Min，CS = Count Sketch。

9 · 答题模板

(A) 估计量分析

1. 定义指示变量/带符号变量；算 $\mathbb{E}$（证无偏或界偏差）。
2. 算 Var（展开平方；交叉项靠两两 / 4-wise 独立消去）。
3. 平均 k 份；Chebyshev ⇒ 常数成功率。
4. $O(\log\frac{1}{\delta})$ 份取中位数 ⇒ $1-\delta$；需要对所有项成立则 union bound。
5. 空间 = 份数 × （计数器位数 + 哈希种子位数）。

(B) 归约证下界

1. 选源问题：Index（查一位）、Gap-Hamming（近似计数）、不相交。
2. Alice 把 x 变成前半段流；Bob 把 i 变成后半段。
3. Alice 跑算法、发内存；Bob 跑完读答案。
4. 证明：输出 YES $\Leftrightarrow x_i = 1$（双向）。
5. 结论：空间 $\geq$ 通信量 $= \Omega(\cdot)$；随机算法对应随机通信下界。

(C) 图流算法 写清楚保留什么子图、加边规则；用不变量证正确性（森林 / 无短环 / 染色）；界住存的边数（$n-1$，或围长 $> 2k$ ⇒ $O(n^{1+1/k})$）；空间 = 边数 $\times 2\log n$。

10 · 常用数

- $\frac{1}{e}\approx 0.368$, $\frac{1}{e^2}\approx 0.135$, 中点 ≈ 0.25
- 几何猜测：$\log_{1+\varepsilon}\Delta = O(\frac{\log\Delta}{\varepsilon})$ 个阈值。
- d 维 γ-net：$\leq (1+\frac{2}{\gamma})^d$ 个点。
- 存 $\leq N$ 的数需 $O(\log N)$ 位；计数器 $\log n$，元素编号 $\log m$。
- k-wise 哈希：k 个系数 ⇒ $O(k\log m)$ 位。