CS5234 Quiz 2 · Cheat Sheet

L6–L11 · k-means 不考 · log = ln

0 · 题型识别 → 工具

- **流式上界**: 维护 sketch / 样本 / 摘要；无偏估计 → 方差 → Chebyshev（mean trick）→ median trick
- **流式下界**: 单向通信；从 Index / Gap-Hamming / Disjointness 归约；把 Bob 的下标编码成关键边/元素
- **允许删除（turnstile）**: 用线性 sketch Rx
- **量级未知**: 转成带阈值 T 的测试问题，并行跑 $T=(1+\varepsilon)^j$
- **近似算法**: 贪心 + 三角不等式；对最优簇用抽屉原理
- **需要多少独立性** 只用 Chebyshev → 两两独立；四阶矩（AMS）→ 4-wise；以 k 个大项为条件 → $(k+2)$-wise

1 · 工具回顾

- Markov $\Pr(X\ge t)\le \mathbb{E}X/t$; Chebyshev $\Pr(|X-\mathbb{E}X|\ge t)\le \mathrm{Var}X/t^2$
- k 份平均: Var/k; 需 $k=\frac{3\mathrm{Var}X}{\varepsilon^2(\mathbb{E}X)^2}$ 得 2/3
- Chernoff (独立, $[0,1]$): $\Pr(|X-\mu|\ge\delta\mu)\le 2e^{-\delta^2\mu/3}$
- Median trick：成功率 $>\frac12$ → $O(\log\frac1\delta)$ 份；对 m 项 union bound 取 $\delta=1/m^2$
- $\{0,1\}$ 变量: $\mathrm{Var}\le\mathbb{E}$; 两两独立 ⇒ 方差可加
- $(1-\frac1T)^T\approx\frac1e, (1-\frac1T)^{2T}\le\frac{1}{e^2}$; $\frac{d^k}{k!}\le(\frac{ed}{k})^k$

2 · L6 聚类

设定 度量 d: $d(p,p)=0$、对称、三角不等式。选 k 个中心，$C(p)$ = 最近中心。k-center: $\min\max_i d(p_i,C(p_i))$; k-median: $\min\sum_i d(p_i,C(p_i))$.

困难性 1-2 度量（距离只取 1、2，三角不等式自动成立）。有大小 k 的支配集 ⇔ k-center 最优 ≤1（有边 → 1，无边 → 2）⇒ 近似比 <2 是 NP-hard。

最远点贪心 = 2-近似 S_i^* 为最优簇，$D(S_i^*)\le OPT$。点 $p\in S_i^*$: (a) 贪心在 S_i^* 里选过 c ⇒ $d(p,c)\le 2OPT$; (b) 没选过 ⇒ k 个中心落在 $k-1$ 个簇 ⇒ 两中心 C_{ℓ_1},C_{ℓ_2} 同簇，距离 $\le 2OPT$; 选 C_{ℓ_2} 时它最远 ⇒ 当时所有点都在 $2OPT$ 内（之后更近）。查询版：nk 次距离查询。

流式 k-center 测试(T)：第一个点作中心；新点离所有中心 $>2T$ → 新中心，已有 k 个则答 No。输出中心 ⇒ 代价 $\le 2T$。No ⇒ $k+1$ 个点两两 $>2T$ ⇒ 半径 T 的球各盖一个 ⇒ $OPT>T$。并行 $T=(1+\varepsilon)^j$，最小非 No 的 T^*: $OPT/2\le T^*\le(1+\varepsilon)OPT$ ⇒ $(2+2\varepsilon)$; 空间 $O(k\frac{\log\Delta}{\varepsilon})$ 个点。

k-median coreset （优于 $1+\frac2e$ 是 NP-hard；最好 $2+\varepsilon$。）每块 $\sqrt{nk}$ 点跑 α-近似 → k 个带权中心放入 S（$O(\sqrt{nk})$ 点）→ 在 S 上再跑 α-近似。
引理 $OPT(P)\le 2OPT^*(P)$ (把自由中心挪到簇内最近输入点).
$\sum d(p_i,C_i)\le\sum d(p_i,s_i)+\sum d(s_i,C_i)$;
$\sum d(p_i,s_i)\le\alpha\sum_j OPT(P_j)\le 2\alpha OPT$;
$\sum d(s_i,C_i)\le 2\alpha\sum d(s_i,C_i^*)\le 2\alpha(2\alpha+1)OPT$
⇒ $(4\alpha^2+4\alpha)$. L 层: $(4\alpha+4)^L, O(Lkn^{1/L})$ 点.

MEB (1-center) 过圆心的任一半平面圆周上都有输入点。贪心：加入最远点、重算 MEB; $\lambda_i=r_i/D$, $\lambda_{i+1}\ge\frac{1+\lambda_i^2}{2}$; $x_i=1-\lambda_i$, $\frac{1}{x_{i+1}}\ge\frac{1}{x_i}+\frac12\Rightarrow t>\frac{10}{\varepsilon}$ 即 $(1+\varepsilon)$; coreset $O(1/\varepsilon)$ 点。

3 · L7 不同元素计数

测试 $h:[m]\to[T]$; $\Pr$[无元素映到 1] $=(1-\frac1T)^{DE}$: $DE\le T$ 时 $\approx\frac1e$, $DE\ge 2T$ 时 $\le\frac{1}{e^2}$。跑 $O(1)$ 份，阈值 $\frac12(\frac1e+\frac{1}{e^2})$，Chernoff。猜 $T=(1+\varepsilon)^j\Rightarrow(2+2\varepsilon)$。完全随机 h 要 $m\log T$ 位。

KMV $h:[m]\to[m], t=\frac{100}{\varepsilon^2}$, $X=t$-小哈希值, 输出 $\widetilde{DE}=\frac{tm}{X}$.
低估 ⇔ 低于 $\frac{tm}{(1-\varepsilon)DE}$ 的哈希值少于 t 个; $Y=\sum Y_i$, $\mathbb{E}Y=\frac{t}{1-\varepsilon}$, $\mathrm{Var}Y\le\mathbb{E}Y$（两两独立）⇒ Chebyshev $\le\frac{1}{10}$; 高估同理; union ⇒ 0.8; median ⇒ $1-\delta$。空间 $O(\varepsilon^{-2}\log m\log\frac1\delta)$. **!删除时失效**

k-wise 独立哈希
$\Pr[h(x_1)=y_1,\dots,h(x_k)=y_k]=m^{-k}$
（x 互异）. $h(x)=\sum_{j<k}c_jx^j$ over $\mathbb{F}_m$ (m 质数). 证明：在 k 点上取值相同的两个多项式之差次数 $\le k-1$ 却有 k 个根 ⇒ 相等; m^k 个多项式与 m^k 组输出一一对应。空间 $O(k\log m)$.

4 · L8 通信复杂度

流式 → 单向通信 Alice 跑前半段，把内存（S 位）发给 Bob，Bob 接着跑。通信下界 C ⇒ 空间 $\ge C$。

Equality 确定性 $\ge n$: $\le n-1$ 位 ⇒ 消息 $\le 2^{n-1}<2^n$ 个输入 ⇒ 两输入同消息，Bob 取 $y=x_1$ 必错其一。随机：发 $r\cdot x \bmod 2$，$x\ne y$ 以 $\frac12$ 被发现，重复 $\log\frac1\delta$ 次；需公共 r。

Newman 公共随机 → 私有随机，多 $O(\log n+\log\frac1\delta)$ 位、错误 $+\delta$: 固定 $t=100n/\delta^2$ 个串；每个输入 Chernoff（$<2^{-10n}$）+ 对 2^{2n} 个输入 union；Alice 发编号 i。

已知难题 Index (x / $i\to x_i$): $\Omega(n)$. Gap-Hamming (Hamming 距离 $\pm\sqrt{n}$): $\Omega(n)$.

归约 A 难（C），额外发 $|M|$ ⇒ B 至少 $C-|M|$。
交集大小 $\pm\frac{\sqrt n}{2}$: Ham $=|X|+|Y|-2|X\cap Y|$, 发 $|X|\Rightarrow\Omega(n)$.
不相交: $X=\{j:x_j=1\}$, $Y=\{i\}\Rightarrow\Omega(n)$。

图流 连通性 $\Omega(n)$: $x_j=1$ 则连 u_A–v_j（Alice）; u_B 连所有 $v_{j\ne i}$ 及 u_A（Bob）⇒ 连通 ⇔ $x_i=1$。完美匹配 $\Omega(n^2)$: n^2 位 Index 编成二分图 u_i–v_j; Bob 给 $u_{i\ne i^*}$、$v_{j\ne j^*}$ 各挂专属替身 ⇒ 有完美匹配 ⇔ $u_{i^*}v_{j^*}$ 有边。MIS $\Omega(n^2)$（两份副本 + 特殊点）。

5 · L9 频率估计

频率矩 $F_p=\sum f_i^p$; F_0=不同元素数, F_1=流长. 碰撞抽样需 $\Theta(\sqrt n/\varepsilon^2)$，太多。

AMS (F_2) $p_i\in\{\pm1\}$, $Z=\sum p_if_i$ (更新 $Z{+}{=}p_x\Delta$), 输出 Z^2.
$\mathbb{E}Z^2=\sum f_i^2$ (交叉项为 0); $\mathbb{E}Z^4=\sum f_i^4+3\sum_{i\ne j}f_i^2f_j^2\le 3F_2^2\Rightarrow \mathrm{Var}Z^2\le 2F_2^2$. 平均 $30/\varepsilon^2$ 份 ⇒ Chebyshev $\le\frac{1}{10}$。符号 4-wise 独立。空间 $O(\varepsilon^{-2}(\log m+\log n))$。

模型 $\Delta=1$ 频率; $\Delta\ge0$ cash register; 任意 turnstile; $x_i\ge0$ 始终 strict turnstile.

线性 sketch 维护 $y=Rx$; 更新 $y\mathrel{+}=\Delta\,Re_i$ ⇒ 天然支持删除。AMS 可以，KMV 不行。F_p $(p>2)$: $\tilde\Theta(m^{1-2/p})$。

Misra-Gries $\le k$ 个计数器；在表里 $+1$；没满就加入；满了全体 -1，删 0。“全体减 1” $\le n/k$ 次 ⇒ $x_i-\frac nk\le c_i\le x_i$。$k=1/\varepsilon$: 误差 εn，确定性，只加不减，非线性。（过半数：一对 (i,c)。）

Count-Min t 行 $\times k$; $C_\ell[h_\ell(i)]\mathrel{+}=\Delta$; $\tilde x_i=\min_\ell$. 多算期望 $\le\|x\|_1/k$; $k=2/\varepsilon$ + Markov ⇒ 单行坏 $<\frac12$; $t=2\log_2 m$ ⇒ $1/m^2$; union ⇒ 对所有 i 成立。只适用 strict turnstile；两两独立哈希。

Count Sketch 再加 $g_\ell:[m]\to\{\pm1\}$; $Y_{\ell,i}=g_\ell(i)C_\ell[h_\ell(i)]$: 无偏, Var $\le\|x\|_2^2/k$; $k=10/\varepsilon^2\Rightarrow$ 0.9; $t=100\log m$ 行取中位数 ⇒ $|\tilde x_i-x_i|\le\varepsilon\|x\|_2$。任意 turnstile。
ℓ_1 大户 → Count-Min; ℓ_2 大户 → Count Sketch。

稀疏恢复 $\|x\|_0\le k$: 下界 $\Omega(k(\log m+\log n))$. 1-稀疏：值 $=\sum\Delta$；位置第 b 位 = [第 b 位为 1 的下标之和 >0]（二分）。一般：随机 0/1 向量 r 以 $\ge\frac12$ 区分 $x\ne y$；固定 $O(k(\log m+\log n))$ 个 r（指数时间）。

6 · L10 数据压缩

近似稀疏恢复 $\mathrm{err}_2^k(x)=\min_{\|z\|_0\le k}\|z-x\|_2$ (保留最大 k 项). Count Sketch, $S=\frac{10k}{\varepsilon^2}$, $t=100\log m$; 保留 x' 最大 k 项。
第 1 步：不撞 k 个大项的概率 $\ge1-\frac{\varepsilon^2}{10}$；此时 $\mathrm{Var}\le\mathrm{err}^2/S\Rightarrow|x_i'-x_i|\le\frac{\varepsilon}{\sqrt k}\mathrm{err}$（$(k+2)$-wise）。
第 2 步：I 选中、J 真大项；漏掉的 j 被冒牌 i 挤掉: $|x_j|\le|x_i|+\frac{2\varepsilon}{\sqrt k}\mathrm{err}$ ⇒ 总 $\le(1+9\varepsilon)\mathrm{err}^2\Rightarrow(1+5\varepsilon)\mathrm{err}$。空间 $O(\varepsilon^{-2}k\log m(\log n+\log m))$.

JL $\Pi_{ij}\sim\mathcal{N}(0,1)$, $k=\frac{\alpha}{\varepsilon^2}\log\frac1\delta$: $\|\frac{1}{\sqrt k}\Pi x\|_2=(1\pm\varepsilon)\|x\|_2$ w.p. $1-\delta$ (与 m 无关). $y_i\sim\mathcal{N}(0,\|x\|_2^2)$; $\Pr[(1-\varepsilon)^2k\le\sum z_i^2\le(1+\varepsilon)^2k]\ge1-2e^{-c\varepsilon^2k}$. n 个点: $\delta=\frac{1}{10n^2}$ + union ⇒ $k=O(\frac{\log n}{\varepsilon^2})$。

线性回归 $L(x)=\|Ax-b\|_2=\|My\|_2$, $M=[A,b]$, $y=(x,-1)$. 若对所有 y 有 $\|\Phi My\|=(1\pm\frac{\varepsilon}{10})\|My\|$: $(1-\frac{\varepsilon}{10})L(\tilde x)\le\tilde L(\tilde x)\le\tilde L(x^*)\le(1+\frac{\varepsilon}{10})L(x^*)\Rightarrow(1+\varepsilon)$.

子空间嵌入 d-维 E, $k=O(\frac{d+\log(1/\delta)}{\varepsilon^2})$ ⇒ 所有 $x\in E$ 被保持. 只看单位向量；$\frac12$-net 大小 $\le5^d$（半径 $\frac\gamma2$ 小球互不相交、都在半径 $1+\frac\gamma2$ 大球内）；对网上的点及差用 JL（$2^{O(d)}$ 个事件）⇒ 内积也保持；$x=\sum z_i$, $\|z_i\|\le2^{1-i}$, $\sum\|z_i\|\le2$ ⇒ 误差 $O(\varepsilon)$。压缩后 $\tilde O(d^2/\varepsilon^2)$ 个数。

7 · L11 图算法

AGM x_v 定义在 $\binom{n}{2}$ 对上：$v = u_1$ 记 $-w$，$v = u_2$ 记 $+w$。$x_S = \sum_{v\in S} x_v$ 恰在离开 S 的边上非零 ⇒ 对 $Rx_S = \sum Rx_v$ 做 ℓ_0 采样。$\log n$ 轮（块数减半），每轮新 sketch（独立性），sampler $O(\log^2 n \log \frac{1}{\delta})$，$\delta = n^{-2}$ ⇒ $O(n \log^4 n)$。

MST 流式 加入 e，成环则删环上最重边。环性质：环上最重边可以不在 MST 里。$O(n)$ 条边。

MST 查询（只估权重） 权重 $\in [W]$，G_i = 权 $\le i$ 的边：$\mathrm{MST} = n - W + \sum_{i=1}^{W-1} \#CC(G_i)$ ($W = 2$: $n - 2 + \#CC(G_1)$). $\#CC$ 用随机截断 r（$\Pr[r \ge i] = \frac{1}{i}$），$x = \mathbf{1}[|CC(v)| \le r]$：偏差 $\le \frac{\varepsilon}{W}$，Var $\le \frac{\#CC}{n}$；$W-1$ 项相加，总方差 $\le 2\varepsilon^2 \mathrm{MST}^2$ ⇒ Chebyshev；$O(\varepsilon^{-2} nW \log \frac{W}{\varepsilon})$ 次查询。MST $\ge n-1$ ⇒ 加性 εn 即相对误差。

MIS（Luby） 随机 $L(v)$；局部最小点全加入，删掉它们和邻居。$X_{wu} = 1$ 若 $L(w)$ 是 $N(w) \cup N(u)$ 中最小：$\mathbb{E} \ge \frac{1}{d_w + d_u}$，删掉 u 的 d_u 条边；每条边至多记两次 ⇒ 期望删掉 $\ge \frac{|E|}{2}$ ⇒ $10 \log n$ 轮 + Markov。多遍：每轮 2 遍，共 $O(\log n)$ 遍，$O(n \log n)$ 位。一遍需 $\Omega(n^2)$。

匹配 极大匹配 $\ge \frac{1}{2}$ 最大匹配。流式贪心：$O(n)$ 条边，2-近似。查询：边的随机值 $L(e)$ 现用现抽；$Q(v)$ 按 L 递增检查 v 的边；$Q(v, e{=}uv)$ = u 没有更早的边 e' 使 $Q(u, e')$；抽 $t = \frac{100}{\varepsilon^2}$ 个点，输出 $\frac{Xn}{2t}$。递归沿 L 递减路径：Pr $\le \frac{d^k}{k!}$，深度 $O(d/\varepsilon)$ ⇒ $d^{O(d/\varepsilon)}$ 次查询。

8 · 易错点

- 哈希函数是固定的：重复元素落进同一格（所以哈希统计的是不同元素）。
- 写明分析需要的独立性（两两 / 4-wise / $(k{+}2)$-wise），并计入空间。
- Count-Min 要求 $x_i \ge 0$；Misra-Gries 只能加；KMV 遇删除失效。
- 下界归约：两个方向都要验证（答案 ⇔ $x_i = 1$），且 Alice 的部分只依赖 x、Bob 的只依赖 i。
- 对“所有 i/所有输入”做 union bound：单项失败率必须远小于 1/项数。

9 · 各 sketch 对比

算法	模型	保证	空间
KMV	只插入	$(1\pm\varepsilon)DE$	$\varepsilon^{-2}\log m$
AMS	任意	$(1\pm\varepsilon)F_2$	$\varepsilon^{-2}\log(mn)$
M-G	只插入	$-\varepsilon n$, 确定	$\varepsilon^{-1}\log(mn)$
CM	strict	$+\varepsilon\|x\|_1$	$\varepsilon^{-1}\log m\log(mn)$
CS	任意	$\pm\varepsilon\|x\|_2$	$\varepsilon^{-2}\log m\log(mn)$
JL	线性	$(1\pm\varepsilon)\|x\|_2$	$\varepsilon^{-2}\log\frac{1}{\delta}$ 行
AGM	任意	生成森林	$n\log^4 n$

KMV/AMS 要 $1-\delta$ 再乘 $\log\frac{1}{\delta}$。M-G = Misra-Gries，CM = Count-Min，CS = Count Sketch。

10 · 答题模板

(A) 估计量分析

1. 定义指示变量/带符号变量；算 $\mathbb{E}$（证无偏或界偏差）。
2. 算 Var（展开平方；交叉项靠两两 / 4-wise 独立消去）。
3. 平均 k 份；Chebyshev ⇒ 常数成功率。
4. $O(\log\frac{1}{\delta})$ 份取中位数 ⇒ $1-\delta$；需要对所有项成立则 union bound。
5. 空间 = 份数 ×（计数器位数 + 哈希种子位数）。

(B) 归约证下界

1. 选源问题：Index（查一位）、Gap-Hamming（近似计数）、不相交。
2. Alice 把 x 变成前半段流；Bob 把 i 变成后半段。
3. Alice 跑算法、发内存；Bob 跑完读答案。
4. 证明：输出 YES ⇔ $x_i = 1$（双向）。
5. 结论：空间 $\ge$ 通信量 $= \Omega(\cdot)$；随机算法对应随机通信下界。

(C) 近似比 固定一个最优解；分情况（抽屉原理：算法有没有选中这个最优簇）；链式用三角不等式；对所有点/簇求和。

11 · 常用数

- $\frac{1}{e} \approx 0.368$, $\frac{1}{e^2} \approx 0.135$, 中点 ≈ 0.25
- 几何猜测：$\log_{1+\varepsilon}\Delta = O(\frac{\log\Delta}{\varepsilon})$ 个阈值。
- d 维 γ-net：$\le (1+\frac{2}{\gamma})^d$ 个点。
- 存 $\le N$ 的数需 $O(\log N)$ 位；计数器 $\log n$，元素编号 $\log m$。
- k-wise 哈希：k 个系数 ⇒ $O(k\log m)$ 位。