CS5234 Mock Quiz 2 — 解答

第 5、7–10 讲 · 开卷 · 50 分钟 · 共 20 分

第 1–4 题单选，每题 1 分。第 5–6 题需写出推理；完全空白的大题给 1 分。log 默认为自然对数。

1 [1 pt]

一串更新 (i, Δ)，Δ 为任意整数（频率可以变成负数）。要对每个 i 给出估计，满足 $|\tilde{x}_i - x_i| \le \varepsilon \|x\|_2$。应选哪个 sketch?

(A) Misra-Gries

(B) Count-Min

(C) Count Sketch

(D) KMV

解答. (C)。Misra-Gries 和 KMV 只能处理插入；Count-Min 要求 $x_i \ge 0$（strict turnstile），且只给 ℓ_1 误差。Count Sketch 是带随机符号的线性 sketch：无偏、方差 $\le \|x\|_2^2/k$，任何 turnstile 流都能用。

2 [1 pt]

KMV 不同元素算法（输出 tm/X，X 为第 t 小的哈希值）中，课上的分析最少需要哈希函数满足哪种独立性?

(A) Fully (mutually) independent

(B) 4-wise independent

(C) Pairwise independent

(D) No independence is needed

解答. (C)。分析只数 $Y = \sum Y_i$（低于阈值的哈希值个数），只用到 $\mathrm{Var}Y = \sum \mathrm{Var}Y_i$ 和 Chebyshev。方差相加只需两两独立，所以两两独立的哈希族（$O(\log m)$ 位）就够。

3 [1 pt]

Morris 计数器每来一个 1 以概率 2^{-C} 令 C 加 1，输出 $2^C - 1$。设 A 为 1 的个数。哪项正确?

(A) $\mathbb{E}[2^C] = A$.

(B) $\mathrm{Var}(2^C) = \frac{A(A-1)}{2}$, so averaging $\frac{10}{\varepsilon^2}$ independent copies gives a $(1 \pm \varepsilon)$-estimate with probability ≥ 0.9.

(C) Each copy needs $\Theta(\log n)$ bits, the same as an exact counter.

(D) The analysis needs a pairwise-independent hash function.

解答. (B)。令 $X_i = 2^{C_i}$：$\mathbb{E}[X_{i+1} \mid X_i = x] = x + 1$，所以 $\mathbb{E}[2^C] = A + 1$（(A) 差 1，这正是输出要减 1 的原因）。$\mathbb{E}[X_{i+1}^2 \mid x] = x^2 + 3x$ 推出 $\mathrm{Var}X_A = \frac{A(A-1)}{2} < A^2$。$k = \frac{10}{\varepsilon^2}$ 份的平均方差 $< \frac{\varepsilon^2 A^2}{10}$，Chebyshev 失败率 $< \frac{1}{10}$。(C) 错：$C \approx \log A$，每份只存 $O(\log \log n)$ 位。(D) 错：Morris 每次抛新硬币，不用哈希。

4 [1 pt]

边流中，算法维护 H，到达的边当且仅当不在 H 中形成长度 ≤ 4 的环时才加入（即 $k = 2$）。哪项正确?

(A) H is a 3-spanner of G with $O(n^{3/2})$ edges.

(B) H is a 4-spanner of G with $O(n\sqrt{n}\log n)$ edges.

(C) H is a 3-spanner, but it can have $\Theta(n^2)$ edges.

(D) H preserves all distances exactly.

解答. (A)。被拒的边 (u, v) 会形成长度 $\le 2k = 4$ 的环，所以 H 里已有一条长度 $\le 3 = 2k - 1$ 的 u–v 路；把最短路上的每条边替换掉，伸缩比为 3。H 的围长 > 4，由 BFS / 最小度论证，边数为 $O(n^{1+1/k}) = O(n^{3/2})$，排除 (C)。伸缩比是 $2k - 1 = 3$ 而不是 4，距离也不是精确保持的（被拒边的两端距离可达 3）。

5 [9 pts]

两个向量 $x, y \in \mathbb{Z}^m$ 初始为 0。同一条流里交替出现更新 (x, i, Δ) 表示 $x_i \mathrel{+}= \Delta$，(y, i, Δ) 表示 $y_i \mathrel{+}= \Delta$，Δ 为任意整数（turnstile）。所有分量绝对值不超过 poly(n)。设计流算法，以概率 $1 - \delta$ 输出 $D = \|x - y\|_2^2$ 的 $(1 \pm \varepsilon)$ 近似。

(a, 2 pts) 描述一个基本估计量：存什么、每条更新怎么处理。为什么 x 和 y 必须用同一组随机符号?

解答. 取 4-wise 独立的 $p:[m]\to\{\pm1\}$，存一个计数器 Z。遇 (x,i,Δ)：$Z\mathrel{+}=p_i\Delta$；遇 (y,i,Δ)：$Z\mathrel{-}=p_i\Delta$。于是 $Z=\sum_i p_ix_i-\sum_i p_iy_i=\sum_i p_iz_i$，$z=x-y$；输出 Z^2。这就是对 z 做 AMS，靠的是 sketch 的线性。若 y 用另一组符号 q，得到的是 $\sum(p_ix_i-q_iy_i)$，不是 z 的 sketch，估计不了 $\|z\|_2^2$。[1 分：sketch 与更新正确；1 分：线性/同符号]

(b, 4 pts) 证明 $\mathbb{E}[Z^2]=D$ 且 $\mathrm{Var}[Z^2]\le 2D^2$，并指出在哪里用到 4-wise 独立。

解答. $\mathbb{E}Z^2=\sum_i z_i^2\mathbb{E}[p_i^2]+\sum_{i\neq j}z_iz_j\mathbb{E}[p_ip_j]=\sum z_i^2=D$，因为 $p_i^2=1$，且 $\mathbb{E}[p_ip_j]=\mathbb{E}p_i\mathbb{E}p_j=0$（两两独立）。四阶矩：$\mathbb{E}Z^4=\sum_{i,j,k,l}z_iz_jz_kz_l\mathbb{E}[p_ip_jp_kp_l]$；由 4-wise 独立，只有下标两两配对的项不为 0：$i=j=k=l$（得 $\sum z_i^4$），或两对不同下标（每个无序对 $\{i,j\}$ 有 6 种排列，得 $6\sum_{i<j}z_i^2z_j^2$）。又 $D^2=\sum z_i^4+2\sum_{i<j}z_i^2z_j^2$，所以 $\mathrm{Var}Z^2=\mathbb{E}Z^4-D^2=4\sum_{i<j}z_i^2z_j^2\le 2D^2$。[1 分：期望；1 分：交叉项因独立为 0；1 分：四阶矩计数；1 分：最终界]

(c, 3 pts) 确定副本数，给出总空间（位）。

解答. 取 $k=6/\varepsilon^2$ 份独立副本平均：$\mathrm{Var}(\bar Z)\le 2D^2/k$，Chebyshev 得 $\Pr[|\bar Z-D|\ge\varepsilon D]\le\frac{2}{k\varepsilon^2}=\frac13$。再对 $r=O(\log\frac1\delta)$ 组平均值取中位数；中位数出错必须有一半组出错，Chernoff 给出概率 $\le\delta$。每份存一个计数器（分量为 $\mathrm{poly}(n)$，$|Z|\le m\cdot\mathrm{poly}(n)$，需 $O(\log m+\log n)$ 位）和 4-wise 哈希种子 $O(\log m)$ 位。总计 $O(\varepsilon^{-2}\log\frac1\delta(\log m+\log n))$。[1 分：mean trick + Chebyshev；1 分：median trick；1 分：空间]

6 [7 pts]

问题 DUP：流是一串 $[m]$ 中的数，算法要判断是否有某个数出现至少两次。可直接使用：m 位 Index 问题的任何错误率 $\le 1/3$ 的随机单向协议都需要 $\Omega(m)$ 位。

(a, 4 pts) 证明：任何成功率 $\ge 2/3$ 的单遍 DUP 流算法都需要 $\Omega(m)$ 位内存。

解答. 从 Index 归约。Alice 有 $x\in\{0,1\}^m$，Bob 有 i。Alice 把 $\{j:x_j=1\}$（每个出现一次）喂给算法，把内存（S 位）发给 Bob。Bob 接着喂入一个元素 i，输出结果。正确性：$x_i=1$ 时 i 已出现过，现在出现两次 ⇒ 答 yes；$x_i=0$ 时每个元素恰出现一次 ⇒ 答 no。因此这个协议以错误率 $\le 1/3$ 解决 Index，只用 S 位，所以 $S=\Omega(m)$。[1 分：Alice 的流；1 分：Bob 的部分 + 消息即内存；1 分：双向正确；1 分：结论]

(b, 1 pt) 为什么流算法是随机的也没关系?

解答. Alice 和 Bob 把算法的随机位当作公共随机数；Index 的 $\Omega(m)$ 下界对错误率 $1/3$ 的随机协议成立（由 Newman 定理，公共/私有随机只差 $O(\log m)$ 位）。

(c, 2 pts) 用同样的思路证明：精确计算不同元素个数 DE 需要 $\Omega(m)$ 位。

解答. Alice 的流不变。Bob 收到内存状态 M 后复制两份：第 1 份直接结束，得 $|X|$；第 2 份喂入 i，得 $|X\cup\{i\}|$。两者相等 $\Leftrightarrow x_i=1$。若算法随机，先放大（$O(1)$ 次取中位数）使每个答案出错 $\le 1/6$，union bound ⇒ 总错 $\le 1/3$。所以需要 $\Omega(m)$ 位。（或者 Alice 额外用 $O(\log m)$ 位直接发 $|X|$。）[1 分：复制两份 / 额外发计数；1 分：相等 $\Leftrightarrow x_i=1$ 及错误处理]