CS5234 Mock Quiz 2 — 解答

第 6–11 讲 · k-means 不考 · 50 分钟 · 共 20 分

第 1–4 题单选，每题 1 分。第 5–6 题需写出推理；完全空白的大题给 1 分。log 默认为自然对数。

1 [1 pt]

一串更新 (i, Δ)，Δ 为任意整数（频率可以变成负数）。要对每个 i 给出估计，满足 $|\tilde{x}_i - x_i| \le \varepsilon \|x\|_2$。应选哪个 sketch?

(A) Misra-Gries

(B) Count-Min

(C) Count Sketch

(D) KMV

解答. (C)。Misra-Gries 和 KMV 只能处理插入；Count-Min 要求 $x_i \ge 0$（strict turnstile），且只给 ℓ_1 误差。Count Sketch 是带随机符号的线性 sketch：无偏、方差 $\le \|x\|_2^2/k$，任何 turnstile 流都能用。

2 [1 pt]

KMV 不同元素算法（输出 tm/X，X 为第 t 小的哈希值）中，课上的分析最少需要哈希函数满足哪种独立性?

(A) Fully (mutually) independent

(B) 4-wise independent

(C) Pairwise independent

(D) No independence is needed

解答. (C)。分析只数 $Y = \sum Y_i$（低于阈值的哈希值个数），只用到 $\mathrm{Var}Y = \sum \mathrm{Var}Y_i$ 和 Chebyshev。方差相加只需两两独立，所以两两独立的哈希族（$O(\log m)$ 位）就够。

3 [1 pt]

关于度量空间上的 k-center，哪项正确（假设 P $\neq$ NP）?

(A) Farthest-first greedy always finds an optimal solution.

(B) Farthest-first greedy is a 2-approximation, and no polynomial-time algorithm achieves ratio 1.9.

(C) For every $\varepsilon > 0$ there is a polynomial-time $(1+\varepsilon)$-approximation.

(D) The approximation ratio of farthest-first greedy grows with k.

解答. (B)。对任意 k 贪心都是 2-近似（抽屉原理 + 三角不等式）。用图构造 1-2 度量：存在大小 k 的支配集 $\Leftrightarrow$ OPT $= 1$，否则 OPT $= 2$；比值 1.9 的算法能区分两种情况，而这是 NP-hard。所以 (C)(D) 错，(A) 也错（问题是 NP-hard）。

4 [1 pt]

连通图有 $n = 10$ 个点，边权为 $\{1, 2, 3\}$ 中的整数。G_i 为权 $\le i$ 的边构成的子图。已知 $\#CC(G_1) = 4$，$\#CC(G_2) = 2$。MST 的权重是多少?

(A) 11

(B) 12

(C) 13

(D) 16

解答. (C)。MST $= n - W + \sum_{i=1}^{W-1} \#CC(G_i) = 10 - 3 + 4 + 2 = 13$。验算：Kruskal 用 $10 - 4 = 6$ 条权 1 的边、$4 - 2 = 2$ 条权 2、$2 - 1 = 1$ 条权 3：$6 + 4 + 3 = 13$。

5 [9 pts]

两个向量 $x, y \in \mathbb{Z}^m$ 初始为 0。同一条流里交替出现更新 (x, i, Δ) 表示 $x_i \mathrel{+}= \Delta$，(y, i, Δ) 表示 $y_i \mathrel{+}= \Delta$，Δ 为任意整数（turnstile）。所有分量绝对值不超过 poly(n)。设计流算法，以概率 $1 - \delta$ 输出 $D = \|x - y\|_2^2$ 的 $(1 \pm \varepsilon)$ 近似。

(a, 2 pts) 描述一个基本估计量：存什么、每条更新怎么处理。为什么 x 和 y 必须用同一组随机符号?

解答. 取 4-wise 独立的 $p : [m] \to \{\pm 1\}$，存一个计数器 Z。遇 (x, i, Δ)：$Z \mathrel{+}= p_i\Delta$；遇 (y, i, Δ)：$Z \mathrel{-}= p_i\Delta$。于是 $Z = \sum_i p_i x_i - \sum_i p_i y_i = \sum_i p_i z_i$，$z = x - y$；输出 Z^2。这就是对 z 做 AMS，靠的是 sketch 的线性。若 y 用另一组符号 q，得到的是 $\sum(p_i x_i - q_i y_i)$，不是 z 的 sketch，估计不了 $\|z\|_2^2$。[1 分：sketch 与更新正确；1 分：线性/同符号]

(b, 4 pts) 证明 $\mathbb{E}[Z^2] = D$ 且 $\mathrm{Var}[Z^2] \le 2D^2$，并指出在哪里用到 4-wise 独立。

解答. $\mathbb{E}Z^2 = \sum_i z_i^2 \mathbb{E}[p_i^2] + \sum_{i \ne j} z_i z_j \mathbb{E}[p_i p_j] = \sum z_i^2 = D$，因为 $p_i^2 = 1$，且 $\mathbb{E}[p_i p_j] = \mathbb{E}p_i \mathbb{E}p_j = 0$（两两独立）。四阶矩：$\mathbb{E}Z^4 = \sum_{i,j,k,l} z_i z_j z_k z_l \mathbb{E}[p_i p_j p_k p_l]$；由 4-wise 独立，只有下标两两配对的项不为 0：$i = j = k = l$（得 $\sum z_i^4$），或两对不同下标（每个无序对 $\{i, j\}$ 有 6 种排列，得 $6 \sum_{i<j} z_i^2 z_j^2$）。又 $D^2 = \sum z_i^4 + 2 \sum_{i<j} z_i^2 z_j^2$，所以 $\mathrm{Var}Z^2 = \mathbb{E}Z^4 - D^2 = 4 \sum_{i<j} z_i^2 z_j^2 \le 2D^2$。[1 分：期望；1 分：交叉项因独立为 0；1 分：四阶矩计数；1 分：最终界]

(c, 3 pts) 确定副本数，给出总空间（位）。

解答. 取 $k = 6/\varepsilon^2$ 份独立副本平均：$\mathrm{Var}(\bar{Z}) \le 2D^2/k$，Chebyshev 得 $\Pr[|\bar{Z} - D| \ge \varepsilon D] \le \frac{2}{k\varepsilon^2} = \frac{1}{3}$。再对 $r = O(\log \frac{1}{\delta})$ 组平均值取中位数；中位数出错必须有一半组出错，Chernoff 给出概率 $\le \delta$。每份存一个计数器（分量为 $\mathrm{poly}(n)$，$|Z| \le m \cdot \mathrm{poly}(n)$，需 $O(\log m + \log n)$ 位）和 4-wise 哈希种子 $O(\log m)$ 位。总计 $O(\varepsilon^{-2} \log \frac{1}{\delta}(\log m + \log n))$。[1 分：mean trick + Chebyshev；1 分：median trick；1 分：空间]

6 [7 pts]

问题 DUP：流是一串 $[m]$ 中的数，算法要判断是否有某个数出现至少两次。可直接使用：m 位 Index 问题的任何错误率 $\le 1/3$ 的随机单向协议都需要 $\Omega(m)$ 位。

(a, 4 pts) 证明：任何成功率 $\ge 2/3$ 的单遍 DUP 流算法都需要 $\Omega(m)$ 位内存。

解答. 从 Index 归约。Alice 有 $x \in \{0,1\}^m$，Bob 有 i。Alice 把 $\{j : x_j = 1\}$（每个出现一次）喂给算法，把内存（S 位）发给 Bob。Bob 接着喂入一个元素 i，输出结果。正确性：$x_i = 1$ 时 i 已出现过，现在出现两次 ⇒ 答 yes；$x_i = 0$ 时每个元素恰出现一次 ⇒ 答 no。因此这个协议以错误率 $\le 1/3$ 解决 Index，只用 S 位，所以 $S = \Omega(m)$。[1 分：Alice 的流；1 分：Bob 的部分 + 消息即内存；1 分：双向正确；1 分：结论]

(b, 1 pt) 为什么流算法是随机的也没关系?

解答. Alice 和 Bob 把算法的随机位当作公共随机数；Index 的 $\Omega(m)$ 下界对错误率 $1/3$ 的随机协议成立（由 Newman 定理，公共/私有随机只差 $O(\log m)$ 位）。

(c, 2 pts) 用同样的思路证明：精确计算不同元素个数 DE 需要 $\Omega(m)$ 位。

解答. Alice 的流不变。Bob 收到内存状态 M 后复制两份：第 1 份直接结束，得 $|X|$；第 2 份喂入 i，得 $|X \cup \{i\}|$。两者相等 $\Leftrightarrow x_i = 1$。若算法随机，先放大（$O(1)$ 次取中位数）使每个答案出错 $\le 1/6$，union bound ⇒ 总错 $\le 1/3$。所以需要 $\Omega(m)$ 位。（或者 Alice 额外用 $O(\log m)$ 位直接发 $|X|$。）[1 分：复制两份 / 额外发计数；1 分：相等 $\Leftrightarrow x_i = 1$ 及错误处理]